

Métodos de estimación

Para obtener estimadores puntuales

Existen los siguientes métodos de estimación:

Método de los Momentos

Método de Máxima Verosimilitud

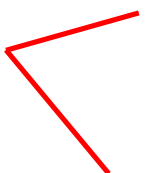
Método Bayesiano

Método de Mínimos Cuadrados

Método de los Momentos:

Consiste en igualar los momentos poblacionales con los muestrales, al resolver estas ecuaciones con valores de parámetros conocidos se obtienen los estimadores.

Momento poblacional de orden $E(X^k)$


$$\sum_{x \in R_x} x^k f(x) \text{ v.a discreta}$$
$$\int_{-\infty}^{+\infty} x^k f(x) dx \text{ v.a continua}$$

Momentos muestrales de orden k: $M_k = \sum_{i=1}^n \frac{X_i^k}{n}$

- Entonces el método consiste en igualar los momentos muestrales con los poblacionales y plantear el sistema de ecuaciones:

$$E(X^k) = \sum_{i=1}^n \frac{X_i^k}{n} \quad k=1, \dots, q$$

Sea X_1, X_2, \dots, X_n v.a iid con $f(x_i, \theta)$ con $\theta \in \Theta \subseteq \mathbb{R}^q$

$$E_{\theta}(X) = \sum_{i=1}^n \frac{X_i}{n}$$

$$E_{\theta}(X^2) = \sum_{i=1}^n \frac{X_i^2}{n}$$

.

.

$$E_{\theta}(X^{q+r}) = \sum_{i=1}^n \frac{X_i^{q+r}}{n}$$

Sistema cuya solución $\hat{\theta}^{MM} = (\hat{\theta}_1^{MM}, \hat{\theta}_2^{MM}, \dots, \hat{\theta}_{q+r}^{MM})$

Este sistema puede ser o no lineal, puede tener o no solución.

- **Ejemplo 1:**

Sea $X_i \sim \varepsilon(\lambda)$ con $f(x_i, \lambda) = \begin{cases} \lambda e^{-\lambda x}; & x_i \geq 0 \\ 0; & c.c \end{cases}$

$\lambda \in \mathbb{R}^+$, en este caso $\theta = \lambda$, $q=1$ $\Theta = \mathbb{R}^+$

$\theta \in \Theta \subseteq \mathbb{R}$

$E(X_i) = M_1$

$\frac{1}{\lambda} = \bar{X}$, despejo λ ,

Por lo tanto el estimador de λ por el Método de los Momentos es:

$$\hat{\lambda}^{MM} = \frac{1}{\bar{X}}$$

- **Ejemplo 2:**

- Sea $X_i \sim U(-\theta, \theta)$ con $\theta \in \mathbb{R}^+$ $q=1$

- $$f(x_i) = \begin{cases} \frac{1}{2\theta}, & -\theta \leq x_i \leq \theta \\ 0, & \text{c.c} \end{cases} \quad E(X_i) = (-\theta + \theta)/2 = 0$$

$E(X_i) = 0$, no depende de θ , busco con otro momento

$$E(X^2) = \sum_{i=1}^n \frac{X_i^2}{n}$$

$$V(X) = E(X^2) - \textcolor{red}{E(X)^2} \text{ entonces, } V(X) = E(X^2) = \frac{(2\theta)^2}{12}$$

$$\frac{(2\theta)^2}{12} = \sum_{i=1}^n \frac{X_i^2}{n} \text{ despejo } \theta$$

$$\theta^2 = 3 \sum_{i=1}^n \frac{X_i^2}{n} \text{ despejo } \theta, \hat{\theta}^{MM} = \sqrt{\frac{3}{n} \sum_{i=1}^n X_i^2}$$

Estimador de Máxima Verosimilitud (E.M.V)

El estimador de Máxima Verosimilitud será el valor del parámetro que maximiza la función de verosimilitud.

Definición:

Supongamos que X es una v.a con distribución de probabilidad $f(x, \theta)$ donde θ es un parámetro desconocido. Sean x_1, x_2, \dots, x_n los valores observados de una m.a de tamaño n . La función de verosimilitud de la muestra es

$L(\theta) = f(x_1, \theta) \dots f(x_n, \theta)$ función de distribución conjunta de la muestra

Por la Independencia es el producto de las función de densidad o de frecuencia según sea el caso

La función de verosimilitud es una función del parámetro desconocido θ . El estimador de máxima verosimilitud de θ es el valor de θ que maximiza la función de verosimilitud $L(\theta)$.

También se lo puede definir como:

Dado $X=(X_1, X_2, \dots, X_n)$ con $X \sim F(x, \theta)$ $\theta \in \Theta \subseteq \mathbb{R}^k$

$$\hat{\theta}^{MV} = \underset{\theta \in \Theta}{\operatorname{Argmax}} f(x, \theta)$$

Pasos para obtener estimadores de Máxima Verosimilitud:

- 1) Encontrar la función de Máxima Verosimilitud
- 2) Aplicar logaritmo en base e, (función continua, creciente y conserva los máximos)
- 3) Derivo respecto al parámetro, e igualo a 0 para buscar puntos críticos
- 4) Despejo el parámetro
- 5) Compruebo que es máximo derivando nuevamente (no se pide)

Ejemplo caso discreto

Ejemplo (caso discreto)

Sea $X \sim P(\lambda)$ su función de frecuencia es $p(x) = e^{-\lambda} \frac{\lambda^x}{x!}$ con $x=0, 1, \dots$

La función de verosimilitud es:

$$L(\lambda) =_{\text{Indep}} p(x_1) \cdot p(x_2) \cdot \dots \cdot p(x_n) = e^{-\lambda} \frac{\lambda^{x_1}}{x_1!} \cdot e^{-\lambda} \frac{\lambda^{x_2}}{x_2!} \cdot \dots \cdot e^{-\lambda} \frac{\lambda^{x_n}}{x_n!} =$$

Agrupando queda:

$$= e^{-n\lambda} \frac{\lambda^{(\sum_{i=1}^n x_i)}}{\prod_{i=1}^n x_i!}$$

Ahora hay que maximizar, aplico ln

$$\begin{aligned}\ln(L(\lambda)) &= \ln\left(e^{-n\lambda} \frac{\lambda^{(\sum_{i=1}^n x_i)}}{\prod_{i=1}^n x_i!}\right) = \ln(e^{-n\lambda}) + \ln(\lambda^{(\sum_{i=1}^n x_i)}) - \ln(\prod_{i=1}^n x_i!) = \\ &= -n\lambda \ln(e) + (\sum_{i=1}^n x_i) \ln(\lambda) - \ln(\prod_{i=1}^n x_i!) = \\ &= -n\lambda \cdot 1 + (\sum_{i=1}^n x_i) \ln(\lambda) - \ln(\prod_{i=1}^n x_i!)\end{aligned}$$

Ahora derivo con respecto a λ :

$$\begin{aligned}\frac{d\ln(L(\lambda))}{d\lambda} &= -n + \sum_{i=1}^n x_i / \lambda = 0 \text{ despejo } \lambda \\ \lambda &= \frac{1}{n} \sum_{i=1}^n x_i, \text{ entonces } \hat{\lambda}^{MV} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}\end{aligned}$$

¿Cómo sé que es máximo?

Verifico con la 2ª derivada (no lo comprobamos)

• **Ejemplo caso continuo:** $X \sim \epsilon(\lambda)$ $f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{si } x \geq 0 \\ 0, & \text{c.c} \end{cases}$

$$L(\lambda) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i} \quad ; \quad \forall i, x_i \geq 0$$

Aplico Ln; $\ln(L(\lambda)) = \ln(\lambda^n e^{-\lambda \sum_{i=1}^n x_i}) =_{\text{prop}} \ln(\lambda^n) + \ln(e^{-\lambda \sum_{i=1}^n x_i}) =$
 $n \ln(\lambda) + (-\lambda \sum_{i=1}^n x_i) \ln(e) = n \ln(\lambda) + (-\lambda \sum_{i=1}^n x_i) \cdot 1$

Ahora derivo con respecto a λ :

$$\frac{d \ln(L(\lambda))}{d\lambda} = n/\lambda - \sum_{i=1}^n x_i = 0 \quad \text{despejo } \lambda,$$

$$\lambda = \frac{n}{\sum_{i=1}^n x_i} \quad \text{con lo cual } \hat{\lambda}^{MV} = \frac{1}{\bar{X}}$$

Observación: notar que con ambos métodos el estimador es el mismo, esto no siempre ocurre

- **Ejemplo:**

Sea X_1, X_2, \dots, X_n m.a de una v.a $U(0, \theta)$, entonces $f(x_i) = \begin{cases} \frac{1}{\theta}, & x_i \in (0, \theta) \\ 0, & c.c \end{cases}$

$$L(\theta) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{1}{\theta} \quad \forall i, x_i \in (0, \theta)$$

$$L(\theta) \stackrel{(*)}{=} \frac{1}{\theta^n} \prod_{i=1}^n I_{(0, \theta)}(x_i) \stackrel{(**)}{=}$$

$$= \frac{1}{\theta^n} I_{(-\infty, \theta)}(\max_i x_i) I_{(0, \infty)}(\min_i x_i)$$


Como la función es decreciente, se maximiza la seleccionar θ tan pequeño como sea posible sujeto a $x_i \in (0, \theta)$.

$$\hat{\theta}^{MV} = \max_i X_i = X_{(n)}$$

(*) defino la función indicadora I como: $I_{(a, b)}(z) = \begin{cases} 1, & z \in [a, b] \\ 0, & c.c \end{cases}$

(**) Notar que $\forall i, i = 1, \dots, n \ x_i \in (0, \theta)$ sii $\max_i x_i \leq \theta$; $\min_i x_i \geq 0$

$L(\theta)$ no es una función continua del parámetro



Como la función $L(\theta)$ es decreciente, se maximiza la selección θ tan pequeño como sea posible sujeto a $x_i \in (0, \theta)$.

El cálculo no funciona porque el máximo ocurre en un punto de discontinuidad.

Propiedades de los E.M.V:

- Son asintóticamente consistentes
- Son asintóticamente insesgados
- Son asintóticamente de varianza mínima

Propiedad de la invarianza:

Sea $\theta \in \Theta \subseteq \mathbb{R}^k$ con $\hat{\theta}^{MV}$ sea $g(\theta)=a$

$$\hat{a}^{MV}=g(\hat{\theta}^{MV})$$

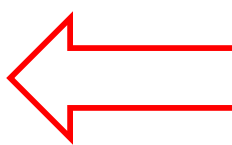
Ejemplo: Sea $X \sim P(\lambda)$

Quiero encontrar el EMV de $P(X=0) = e^{-\lambda} \frac{\lambda^0}{0!} = e^{-\lambda} = g(\lambda)$

$$P(\widehat{X} = 0) = \widehat{g(\lambda)} \underset{\substack{= \\ \text{prop inv.}}}{=} g(\hat{\lambda}^{MV})$$

Aplicamos a nuestro ejemplo:

$$P(\widehat{X} = 0) = e^{-\hat{\lambda}} \underset{\substack{= \\ \text{prop inv.}}}{=} e^{-\hat{\lambda}} \underset{\substack{= \\ (*)}}{=} e^{-\bar{X}}$$



(*) reemplazo
por $\hat{\lambda}^{MV} = \bar{X}$

Por lo tanto: El EMV de $P(X=0)$ es $e^{-\bar{X}}$