# Programación I

Organización de Computadoras

Segunda Parte

# Temas de la segunda parte

- Representación de datos ←
- Números enteros
- Operaciones aritméticas
- Punto fijo
- Punto flotante

## Representación de datos

Las computadoras almacenan datos e instrucciones en memoria.

Para ello utilizan el sistema binario.

### Razones:

- El dispositivo se encuentra en uno de dos estados posibles (0 ó 1)
- Identificar el estado es más fácil si sólo hay dos

## Representación de datos

- Ejemplo:
  - lámpara encendida o apagada
  - lámpara encendida con 10 intensidades distintas
- Es más fácil conocer el "estado" de la lámpara en el primer caso (encendida o apagada), que determinar alguna de las 10 intensidades distintas

 Como contrapartida, no es humanamente intuitivo dado que estamos acostumbrados a cuantificar las cosas en decimal.

## Representación de datos

Las computadoras manejan varios tipos básicos de datos binarios

- Números enteros sin/con signo
  - o -50; 0; 3; 85
- Números reales con signo
  - -34,5; 78,33; 3,14
- Caracteres (codificación o encoding)
  - ASCII
  - ISO 8859-X
  - UTF-8

## Representación de datos. Datos alfanuméricos.

Representación alfanumérica.

El conjunto de caracteres abarca:

- Letras ('A' ... 'Z' y 'a' ... 'z')
- Dígitos decimales ('0', ..., '9')
   ← OJO: 0 <> '0'
- Signos de puntuación (:, ;, ,, .)
- Caracteres especiales (#, \$, %, !, SP, etc.)
- Ordenes de control (CR, LF, ESC, NUL, etc.)

## Representación de datos. Datos alfanuméricos.

La representación alfanumérica simplemente requiere un código binario para cada caracter:

A mayor número de bits por carácter, mayor cantidad de caracteres distintos se podrán representar.

- Con 3 bits podré representar 8 (2<sup>3</sup>) caracteres distintos
- Con 4 bits podré representar 16 (2<sup>4</sup>) caracteres distintos
- Con 7 bits podré representar 128 (2<sup>7</sup>) caracteres distintos
- Con 8 bits podré representar 256 (28) caracteres distintos

## Representación de datos. Codificaciones.

Algunos ejemplos de codificación:

#### FIELDATA

- Código de 6 bits → Total 64 combinaciones
- 26 letras mayúsculas + 10 dígitos + 28 caracteres especiales
- ASCII: American Standard Code for Information Interchange
  - FIELDATA + minúsculas + CONTROL
  - Código de 7 bits → Total 128 combinaciones

#### ASCII Extendido

- ASCII + multinacional + semigráficos + matemáticos
- Código de 8 bits → Total 256 combinaciones
- **EBCDIC**: Extended BCD Interchange Code
  - Similar al ASCII pero de IBM
  - Código de 8 bits → Total 256 combinaciones

#### UTF-8

Codificación de longitud variable

## Representación de datos. ASCII Extendido.

A	SCII	contro	ol characters			ASC	II pri	ntable
DEC HEX		Si	mbolo ASCII	DEC	HEX	Simbolo	DEC	HEX
00	00h	NULL	(carácter nulo)	32	20h	espacio	64	40h
01	01h	SOH	(inicio encabezado)	33	21h	!	65	41h
02	02h	STX	(inicio texto)	34	22h		66	42h
03	03h	ETX	(fin de texto)	35	23h	#	67	43h
04	04h	EOT	(fin transmisión)	36	24h	\$	68	44h
05	05h	ENQ	(enquiry)	37	25h	%	69	45h
06	06h	ACK	(acknowledgement)	38	26h	&	70	46h
07	07h	BEL	(timbre)	39	27h	•	71	47h
08	08h	BS	(retroceso)	40	28h	(	72	48h
09	09h	HT	(tab horizontal)	41	29h	j	73	49h
10	0Ah	LF	(salto de linea)	42	2Ah	*	74	4Ah
11	0Bh	VT	(tab vertical)	43	2Bh	+	75	4Bh
12	0Ch	FF	(form feed)	44	2Ch	,	76	4Ch
13	0Dh	CR	(retorno de carro)	45	2Dh	2	77	4Dh
14	0Eh	SO	(shift Out)	46	2Eh		78	4Eh
15	0Fh	SI	(shift In)	47	2Fh	1	79	4Fh
16	10h	DLE	(data link escape)	48	30h	0	80	50h
17	11h	DC1	(device control 1)	49	31h	1	81	51h
18	12h	DC2	(device control 2)	50	32h	2	82	52h
19	13h	DC3	(device control 3)	51	33h	3	83	53h
20	14h	DC4	(device control 4)	52	34h	4	84	54h
21	15h	NAK	(negative acknowle.)	53	35h	5	85	55h
22	16h	SYN	(synchronous idle)	54	36h	6	86	56h
23	17h	ETB	(end of trans, block)	55	37h	7	87	57h
24	18h	CAN	(cancel)	56	38h	8	88	58h
25	19h	EM	(end of medium)	57	39h	9	89	59h
26	1Ah	SUB	(substitute)	58	3Ah		90	5Ah
27	1Bh	ESC	(escape)	59	3Bh		91	5Bh
28	1Ch	FS	(file separator)	60	3Ch	2	92	5Ch
29	1Dh	GS	(group separator)	61	3Dh	2	93	5Dh
30	1Eh	RS	(record separator)	62	3Eh	>	94	5Eh
31	1Eh	US	(unit separator)	63	3Fh	?	95	5Fh
127	20h	DEL	(delete)	0.5	75.0	*	0.0	-

		ASC	II pri	ntabl	e charact	ters		
DEC	HEX	Simbolo	DEC	HEX	Simbolo	DEC	HEX	Simbolo
32	20h	espacio	64	40h	@	96	60h	•
33	21h	1	65	41h	A	97	61h	a
34	22h		66	42h	В	98	62h	b
35	23h	#	67	43h	C	99	63h	C
36	24h	\$	68	44h	D	100	64h	d
37	25h	%	69	45h	E	101	65h	e
38	26h	&	70	46h	F	102	66h	f
39	27h	•	71	47h	G	103	67h	g
40	28h	(	72	48h	Н	104	68h	ĥ
41	29h	j	73	49h	1	105	69h	i
42	2Ah	*	74	4Ah	J	106	6Ah	j
43	2Bh	+	75	4Bh	K	107	6Bh	k
44	2Ch		76	4Ch	L	108	6Ch	1
45	2Dh	2	77	4Dh	M	109	6Dh	m
46	2Eh	*	78	4Eh	N	110	6Eh	n
47	2Fh	1	79	4Fh	0	111	6Fh	0
48	30h	0	80	50h	P	112	70h	р
49	31h	1	81	51h	Q	113	7.1h	q
50	32h	2	82	52h	R	114	72h	r
51	33h	3	83	53h	S	115	73h	S
52	34h	4	84	54h	T	116	74h	t
53	35h	5	85	55h	U	117	75h	u
54	36h	6	86	56h	V	118	76h	v
55	37h	7	87	57h	W	119	77h	w
56	38h	8	88	58h	X	120	78h	x
57	39h	9	89	59h	Y	121	79h	y
58	3Ah	:	90	5Ah	Z	122	7Ah	z
59	38h	;	91	5Bh	1000	123	7Bh	{
60	3Ch	<	92	5Ch	Ĺ	124	7Ch	ì
61	3Dh	=	93	5Dh	]	125	7Dh	}
62	3Eh	>	94	5Eh	Ä	126	7Eh	~
63	3Fh	?	95	5Fh	_	theA	SCIIco	de.com.ar

Extended ASCII characters											
DEC	HEX	Simbolo	DEC	HEX	Simbolo	DEC	HEX	Simbolo	DEC	HEX	Simbolo
128	80h	Ç	160	A0h	á	192	COh	L	224	E0h	Ó
129	81h	ü	161	A1h	í	193	C1h	1	225	E1h	B
130	82h	é	162	A2h	Ó	194	C2h	т	226	E2h	Ô
131	83h	â	163	A3h	ú	195	C3h	Ţ	227	E3h	
132	84h	ä	164	A4h	ñ Ñ	196	C4h	-	228	E4h	ő
133	85h	à	165	A5h	Ñ	197	C5h	+ ã Ā	229	E5h	Ő
134	86h	å	166	A6h	a	198	C6h	ä	230	E6h	μ
135	87h	ç	167	A7h	0	199	C7h	A	231	E7h	þ
136	88h	ç	168	A8h	ż	200	C8h	L	232	E8h	Þ Þ Ú Ú Ú Ú Ú
137	89h	ë	169	A9h	®	201	C9h	F	233	E9h	Ú
138	8Ah	è	170	AAh	7	202	CAh	1	234	EAh	Û
139	8Bh	ï	171	ABh	1/2	203	CBh	TE	235	EBh	Ù
140	8Ch	î	172	ACh	1/4	204	CCh	Ţ	236	ECh	ý
141	8Dh	ì	173	ADh	i	205	CDh		237	EDh	Ý
142	8Eh	Ä	174	AEh	ec .	206	CEh	# #	238	EEh	0.70
143	8Fh	A	175	AFh	30	207	CFh	n	239	EFh	*
144	90h	É	176	BOh	<b>30</b>	208	D0h	ð	240	FOh	
145	91h	æ	177	B1h	222	209	D1h	Ð	241	F1h	±
146	92h	Æ	178	B2h		210	D2h	Đ Ē Ē	242	F2h	
147	93h	ô	179	B3h	T	211	D3h	Ë	243	F3h	3/4
148	94h	ò	180	B4h	4	212	D4h	È	244	F4h	1
149	95h	ò	181	B5h	À	213	D5h	1	245	F5h	8
150	96h	û	182	B6h	Ā Ā	214	D6h	ĺ	246	F6h	÷
151	97h	ù	183	87h	À	215	D7h	Î	247	F7h	
152	98h	Ÿ	184	B8h	0	216	D8h	Ï	248	F8h	ô
153	99h	ý	185	B9h	4	217	D9h	٦	249	F9h	446
154	9Ah	Ü	186	BAh	1	218	DAh	г	250	FAh	
155	9Bh	Ø	187	BBh		219	DBh		251	FBh.	1
156	9Ch	£	188	BCh	]	220	DCh		252	FCh	8
157	9Dh	Ø	189	BDh	¢	221	DDh	Ţ	253	FDh	2
158	9Eh	×	190	BEh	¥	222	DEh	ì	254	FEh	
159	9Fh	f	191	BFh	٦	223	DFh		255	FFh	

## Representación de datos. UTF-8


#### UTF-8

Permite codificación de longitud variable (hasta 4 bytes), lo que permite representar más de 1.000.000 de caracteres distintos.


Fue concebido considerando la retrocompatibilidad con ASCII.

Es actualmente el formato de codificación más utilizado.

Solo hay codificada una porción del total posible de caracteres: Unicode v11 (Junio 2018): 137.374 caracteres.



## Representación de datos. UTF-8



http://www.unicode.org

https://unicode-table.com

## Representación de datos. Números.

La representación alfanumérica es mayormente sencilla de comprender. Sin embargo...

- ¿Cómo representar/almacenar valores decimales en binario?
- ¿Cómo representar/almacenar un signo negativo, una coma decimal?
- ¿Qué valor decimal representa la siguiente secuencia de dígitos binarios?

## 1001

## Representación de datos. Números.

¿1001 qué valor en decimal representa?

```
a) 9
   4,5
c) 2,25
d) -1
e) -0.5
f) -0,25
g) -6
h) -7
```

## Representación de datos. Números.

## ¿1001 qué valor en decimal representa?

- a) 9 ← BSS
- b) 4,5 ← BSS, 1 bit para fracción
- c) 2,25 ← BSS, 2 bits para fracción
- d) -1 ← BCS
- e) -0,5 ← BCS, 1 bit para fracción
- f) -0,25 ← BCS, 2 bits para fracción
- g) -6 ← Ca1
- h) -7 ← Ca2
- i) 1 ← Ex2

Necesitamos saber el sistema de representación utilizado para poder determinar qué valor se encuentra almacenado en la secuencia de dígitos binarios especificada.

# Temas de la segunda parte

- Representación de datos
- Números enteros ←
- Operaciones aritméticas
- Punto fijo
- Punto flotante

## Representación de números enteros

- Sin signo
  - Binario sin signo (**BSS**)
- Módulo y signo
  - Binario con signo (BCS)
- Complemento a la base reducida
  - Complemento a uno (Ca1)
- Complemento a la base
  - Complemento a dos (Ca2)
- Exceso
  - Exceso base 2 (Ex2)

Teorema Fundamental de la Numeración

$$N^{\circ} = \sum_{i=-m}^{n} (digito)_{i} \times (base)^{i}$$

... + 
$$x_4 \times B^4 + x_3 \times B^3 + x_2 \times B^2 + x_1 \times B^1 + x_0 \times B^0 + x_{-1} \times B^{-1} + x_{-2} \times B^{-2} + ...$$

N° es el valor decimal de una cantidad expresada en base B a lo largo de las posiciones i-ésimas comprendidas entre -m y n

Sistema decimal: Base 10

$$= 8 \times 10^3 + 5 \times 10^2 + 7 \times 10^1 + 4 \times 10^0$$

$$+ 4 \times 10^{0}$$

$$16 = 3 + 0.1 + 0.04 + 0.001 + 0.0006$$
$$= 3 \times 10^{0} + 1 \times 10^{-1} + 4 \times 10^{-2} + 1 \times 10^{-3} + 6 \times 10^{-4}$$

Sistema binario: Base 2

Digitos {0, 1}

**1001,1**<sub>2</sub> = 
$$1 \times 2^3 + 0 \times 2^2 + 0 \times 2^1 + 1 \times 2^0 + 1 \times 2^{-1}$$
  
=  $8 + 0 + 0 + 0 + 1 + 0,5$   
=  $9,5_{10}$ 

Sistema hexadecimal: Base 16

$$2CA,8_{16} = 2 \times 16^{2} + C \times 16^{1} + A \times 16^{0} + 8 \times 16^{-1}$$

$$= 512 + 192 + 10 + 0,5$$

$$= 714,5_{10}$$

## BCH. Hexadecimal Codificado en Binario

Dígito hexadecimal	Código BCH
0	0000
1	0001
2	0010
3	0011
4	0100
5	0101
6	0110
7	0111
8	1000
9	1001
A	1010
В	1011
С	1100
D	1101
E	1110
F	1111

Abstracción para simplificar la lectura, dado que 4 dígitos binarios se agrupan en un solo dígito hexadecimal.

Por ejemplo, la cadena **AB9D**<sub>16</sub> es más sencillo de leer e interpretar que **1010101110011101**<sub>2</sub>


## BCH. Hexadecimal Codificado en Binario

Dígito hexadecimal	Código BCH
0	0000
1	0001
2	0010
3	0011
4	0100
5	0101
6	0110
7	0111
8	1000
9	1001
A	1010
В	1011
С	1100
D	1101
E	1110
F	1111

```
Windows
A fatal exception 0E has occurred at 0028:C562F1B7 in UXD ctpci9x(05)
+ 00001853. The current application will be terminated.
* Press any key to terminate the current application.
* Press CIRL+ALT+DEL again to restart your computer. You will
   lose any unsaved information in all applications.
                     Press any key to continue _
```

## BCH. Hexadecimal Codificado en Binario

Dígito hexadecimal	Código BCH
0	0000
1	0001
2	0010
3	0011
4	0100
5	0101
6	0110
7	0111
8	1000
9	1001
A	1010
В	1011
С	1100
D	1101
E	1110
F	1111



## BCD. Decimal Codificado en Binario

Dígito decimal	Código BCD
0	0000
1	0001
2	0010
3	0011
4	0100
5	0101
6	0110
7	0111
8	1000
9	1001
2 3 4 5 6 7	0010 0011 0100 0101 0110 0111 1000

De las 16 combinaciones con 4 bits, se utilizan 10 para representar los dígitos del 1 al 9. Sobran 6 combinaciones de 4 bits para utilizarlos según el ámbito de aplicación (sincronismo, operadores aritméticos, etc.)

#### Sistema de representación:

- Los dígitos decimales se convierten uno a uno en binario
- Para representar un dígito decimal se requerirán 4 bits
- Se asocia cada dígito con su valor en binario puro

#### Dos ámbitos de aplicación:

- <u>E/S y periféricos</u>, los números se codifican usando 8 bits por dígito. Se dice que el número está desempaquetado.
- <u>En cálculo</u>, se reservan 4 bits por dígito. Se dice que el número está empaquetado.

## BCD. Decimal Codificado en Binario

Dígito decimal	Código BCD
0	0000
1	0001
2	0010
3	0011
4	0100
5	0101
6	0110
7	0111
8	1000
9	1001

De las 16 combinaciones con 4 bits, se utilizan 10 para representar los dígitos del 1 al 9. Sobran 6 combinaciones de 4 bits para utilizarlos según el ámbito de aplicación (sincronismo, operadores aritméticos, etc.)

#### E/S y Periféricos

Por cada dígito se usan 8 bits, 4 para el binario puro y 4 se completan con "1"

#### Cálculo

Ciertas combinaciones se usan para operadores

```
C_{16} = 1100 representa al signo + D_{16} = 1101 representa al signo -
```

**BCD** tiene usos específicos y NO fue concebido para maximizar la capacidad de representación en función del número total de combinaciones.

# Enteros sin signo. Binario Sin Signo (BSS).

Si el número tiene **n** bits, es posible representar **2**<sup>n</sup> números distintos. El **rango** comprende desde **0** hasta **2**<sup>n</sup>**–1** 

Ejemplo con 3 bits:  $2^3 = 8$  números distintos. Rango:  $0 ... 2^3-1 = 0 ... 7$ 

```
\begin{array}{cccc}
000_{2} & 0 \\
001_{2} & 1 \\
010_{2} & 2 \\
011_{2} & 3 \\
100_{2} & 4 \\
101_{2} & 5 \\
110_{2} & 6 \\
111_{2} & 7
\end{array}
```

# Enteros sin signo. Binario Sin Signo (BSS).

Ejemplo con 8 bits:  $2^8 = 256$  números distintos. Rango:  $0 ... 2^8 - 1 = 0 ... 255$ 

```
000000002
00000001, 1
00000102
01111111<sub>2</sub>
                127
100000002
                128
10000001,
                129
                 . . .
11111110,
                254
11111111<sub>2</sub>
                255
```

# Enteros sin signo. Binario Sin Signo (BSS).

En BSS es posible representar la misma cantidad de números distintos que combinaciones posibles de bits.

Ejemplo: Con 8 bits se pueden realizar 256 combinaciones.

En BSS con 8 bits se pueden representar 256 números distintos.

No todos los sistemas maximizan la capacidad de representación en función del número de combinaciones posibles.

¿Cómo representar valores negativos en una computadora?

¿Cómo almacenar el signo - (menos)?

Debemos "robar" un bit a la magnitud para poder almacenar el signo

Bit 7 (signo)	Bit 6	Bit 5	Bit 4	Bit 3	Bit 2	Bit 1	Bit 0
	(magnitud)						

- Un 0 en el bit de signo indica que el número es positivo
- Un 1 en el bit de signo indica que el número es negativo

Los bits **0** a **n-2** representan el valor absoluto en binario.

Ejemplos: 
$$1010_2 = -2$$
  $0010_2 = 2$ 

$$0010_2 = 2$$

El rango: -(2<sup>n-1</sup>-1) .. (2<sup>n-1</sup>-1) con 2 ceros: 0000 y 1000

Ejemplo con 3 bits:  $2^3-1 = 7$  números distintos. Rango:  $-(2^2-1) ... 2^2-1 = -3 ... 3$  (intervalo <u>simétrico</u>)

0002	0
001 <sub>2</sub>	1
0102	2
011 <sub>2</sub>	3
1002	-0
101 <sub>2</sub>	-1
110 <sub>2</sub>	-2
111,	-3

Ejemplo con 8 bits:  $2^8-1 = 255$  números distintos. Rango:  $-(2^7-1) ... 2^7-1 = -127 ... 127$  (intervalo <u>simétrico</u>)

```
00000000
00000001
0000010,
                127
01111111<sub>2</sub>
100000002
10000001,
                -1
11111110,
               -126
11111111<sub>2</sub>
                -127
```

En BCS no es posible representar la misma cantidad de números distintos que combinaciones posibles de bits.

Ejemplo: Con 8 bits se pueden realizar 256 combinaciones. En BCS con 8 bits se pueden representar 255 números distintos.

BCS **no** maximiza la capacidad de representación en función del número de combinaciones posibles, debido al doble cero.

Utilizado en ciertas (pocas) computadoras de vieja data



IBM 7090

# Enteros con signo. Complemento a 1 (Ca1).

Complemento: El complemento a un número N de un número A es igual a la cantidad que le falta a A para ser N (A menor que N)

## "Complemento a N de A = N - A"

Complemento a 26 de 3 = 23

Complemento a 12 de 4 = 8

Complemento a 7 de 7 = 0

¿Cómo aplicar este concepto para definir números negativos?

## Enteros con signo. Complemento a 1 (Ca1).

## **Definición**: Si un número binario está expresado en Ca1:

- Si el bit más significativo es 0, el número es positivo y se interpreta como BSS.
- Si el bit más significativo es 1, el número es negativo y se interpretará el Ca1 del valor.

## Ca1 → ¿Qué valor de N utilizar?

Para cualquier número con  $\mathbf{n}$  cantidad de dígitos binarios,  $\mathbf{N}$  se define como:  $\mathbf{N} = \mathbf{2}^{n} - \mathbf{1}$  (complemento <u>a la base reducida</u> o  $\mathbf{Ca1}$ )

- Si n = 1  $\rightarrow$  N =  $2^1 1 = 1$
- Si n =  $2 \rightarrow N = 2^2 1 = 3$
- Si n =  $3 \rightarrow N = 2^3 1 = 7$
- Si n =  $4 \rightarrow N = 2^4 1 = 15$

# Enteros con signo. Complemento a 1 (Ca1).

- Si n = 1  $\rightarrow$  N =  $2^1$  1 = 1
- Si n =  $2 \rightarrow N = 2^2 1 = 3$
- Si n =  $3 \rightarrow N = 2^3 1 = 7$
- Si n =  $4 \rightarrow N = 2^4 1 = 15$

#### Ejemplo acotado a 3 bits:

- 010 (2 en decimal)
  - Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 2
- 110 (6 en decimal)
  - Inicia con 1. Se interpreta negativo.
  - Se lee el Ca1 de 6: 7 6 = 1
  - Valor: -1

- Si n = 1  $\rightarrow$  N =  $2^1$  1 = 1
- Si n =  $2 \rightarrow N = 2^2 1 = 3$
- Si n =  $3 \rightarrow N = 2^3 1 = 7$
- Si n =  $4 \rightarrow N = 2^4 1 = 15$

#### Ejemplo acotado a 4 bits:

- 0101 (5 en decimal)
  - o Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 5
- 1001 (9 en decimal)
  - Inicia con 1. Se interpreta negativo.
  - Se lee el Ca1 de 9: 15 9 = 6
  - o Valor: -6

- Si n = 1  $\rightarrow$  N =  $2^1$  1 = 1
- Si n =  $2 \rightarrow N = 2^2 1 = 3$
- Si n =  $3 \rightarrow N = 2^3 1 = 7$
- Si n =  $4 \rightarrow N = 2^4 1 = 15$

#### Ejemplo acotado a 4 bits:

- 0111 (7 en decimal)
  - o Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 7
- 1111 (15 en decimal)
  - Inicia con 1. Se interpreta negativo.
  - Se lee el Ca1 de 15: 15 15 = 0
  - Valor: -0

#### Una técnica más sencilla

Leer el Ca1 de una secuencia de dígitos binarios simplemente implica "invertir" los dígitos de dicho número, y luego leerlo como BSS (adicionando previamente el -)

De esta manera no hay necesidad de "determinar" el valor de N en función de n.

Aplicamos la nueva aproximación en los ejemplos anteriores:

- Nro negativo expresado en Ca1 → Invierto bits → Leo en BSS → Agrego el signo -
- $110 \rightarrow 001 \rightarrow 1 \rightarrow -1$
- $1001 \rightarrow 0110 \rightarrow 6 \rightarrow -6$
- $1111 \rightarrow 0000 \rightarrow 0 \rightarrow -0$

Números a representar igual que en BCS. Ejemplo con 3 bits:  $2^3-1 = 7$  números distintos.

0002	0
0012	1
0102	2
011 <sub>2</sub>	3
1002	-3
1012	-2
1102	-1
111,	-0

El rango es el mismo que en BCS:  $-(2^2-1) ... 2^2-1 = -3 ... 3$  (intervalo <u>simétrico</u>)

Ejemplo con 8 bits:  $2^8-1 = 255$  números distintos. Rango:  $-(2^7-1) ... 2^7-1 = -127 ... 127$  (intervalo <u>simétrico</u>)

```
00000000
00000001
0000010,
                 127
01111111<sub>2</sub>
10000000 -127
10000001,
                -126
11111110,
11111111<sub>2</sub>
```

En Ca1 no es posible representar la misma cantidad de números distintos que combinaciones posibles de bits.

Ejemplo: Con 8 bits se pueden realizar 256 combinaciones.

En Ca1 con 8 bits se pueden representar 255 números distintos.

Presenta el mismo problema del doble cero que BCS.

Al igual que el BCS, el Ca1 **no** maximiza la capacidad de representación en función del número de combinaciones posibles.

#### Entonces... ¿para qué sirve?

Igualmente sirve como un sistema de representación de números negativos.

Varios computadores lo han utilizado.



CDC 6600



UNIVAC 1100



PDP-1

Adicionalmente sirve como introducción a Complemento a 2.

#### Complemento a 2 (Ca2)

Por su definición, Ca2 es una mejora con respecto a Ca1 dado que no presenta el problema del doble cero.

Ca2 es un sistema de representación muy utilizado en computadoras para representar números de punto fijo negativos.

#### **<u>Definición</u>**: Si un número binario está expresado en Ca2:

- Si el bit más significativo es 0, el número es positivo y se interpreta como BSS.
- Si el bit más significativo es 1, el número es negativo y se interpretará el Ca2 del valor.

#### Ca2 → ¿Qué valor de N utilizar?

Para cualquier número con n cantidad de dígitos binarios, n se define como: n = n (complemento n la base o n Ca2)

- Si n = 1  $\rightarrow$  N =  $2^1$  = 2
- Si  $n = 2 \rightarrow N = 2^2 = 4$
- Si n =  $3 \rightarrow N = 2^3 = 8$
- Si n =  $4 \rightarrow N = 2^4 = 16$

- Si n = 1  $\rightarrow$  N =  $2^1$  = 2
- Si n =  $2 \rightarrow N = 2^2 = 4$
- Si n =  $3 \rightarrow N = 2^3 = 8$
- Si n =  $4 \rightarrow N = 2^4 = 16$

#### Ejemplo acotado a 3 bits:

- 010 (2 en decimal)
  - Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 2
- 110 (6 en decimal)
  - Inicia con 1. Se interpreta negativo.
  - Se lee el Ca2 de 6: 8 6 = 2
  - Valor: -2

- Si n = 1  $\rightarrow$  N =  $2^1$  = 2
- Si n =  $2 \rightarrow N = 2^2 = 4$
- Si n =  $3 \rightarrow N = 2^3 = 8$
- Si n =  $4 \rightarrow N = 2^4 = 16$

#### Ejemplo acotado a 4 bits:

- 0101 (5 en decimal)
  - Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 5
- 1001 (9 en decimal)
  - Inicia con 1. Se interpreta negativo.
  - Se lee el Ca2 de 9: 16 9 = 7
  - Valor: -7

- Si n = 1  $\rightarrow$  N =  $2^1$  = 2
- Si n =  $2 \rightarrow N = 2^2 = 4$
- Si n =  $3 \rightarrow N = 2^3 = 8$
- Si n =  $4 \rightarrow N = 2^4 = 16$

#### Ejemplo acotado a 4 bits:

- 0111 (7 en decimal)
  - Inicia con 0. Se interpreta positivo.
  - Se lee como BSS. Valor: 7
- 1111 (15 en decimal)
  - o Inicia con 1. Se interpreta negativo.
  - Se lee el Ca2 de 15: 16 15 = 1
  - Valor: -1

← (En Ca1 era el -0)

#### Una técnica más sencilla

Leer el Ca2 de una secuencia de dígitos binarios simplemente implica interpretar primeramente el Ca1 y luego restarle 1.

(Notar que - por definición de complementos a la base y a la base reducida - Ca2 tiene un delta de 1 unidad con respecto a Ca1).

Aplicamos la nueva aproximación en los ejemplos anteriores:

- Nro negativo expresado en Ca2 → Interpreto en Ca1 → Resto 1
- 110 → -1 → **-2**
- $1001 \rightarrow -6 \rightarrow -7$
- $1111 \rightarrow -0 \rightarrow -1$   $\leftarrow$  No más doble cero!

Ejemplo con 3 bits:  $2^3 = 8$  números distintos (contra 7 de BCS y Ca1)

El rango es mayor al de Ca1 :  $-(2^2)$  ..  $2^2-1 = -4$  .. 3 (intervalo <u>asimétrico</u>)

Ejemplo con 8 bits:  $2^8 = 256$  números distintos. Rango:  $-(2^7) ... 2^7 - 1 = -128 ... 127$  (intervalo <u>asimétrico</u>)

```
000000002
00000001
0000010
               127
01111111<sub>2</sub>
10000000 -128
10000001,
              -127
11111110,
111111111,
```

En Ca2 sí es posible representar la misma cantidad de números distintos que combinaciones posibles de bits.

Ejemplo: Con 8 bits se pueden realizar 256 combinaciones.

En Ca2 con 8 bits se pueden representar 256 números distintos.

No presenta el problema del doble cero como Ca1 y BCS.

A diferencia de BCS y Ca1, **Ca2 maximiza** la capacidad de representación en función del número de combinaciones posibles.

#### Técnica del exceso

- La representación de un número A en exceso es la que corresponde a la SUMA del mismo y un valor constante E (o exceso).
  - Exceso E de A = A + E

- Dado un valor en exceso, el número representado se obtiene RESTANDO el valor del exceso.
  - A = (Exceso E de A) E

#### Técnica del exceso

#### Simplificado:

- Si quiero expresar un número en exceso, sumo el exceso.
- Si quiero interpretar un número expresado en exceso, resto el exceso.
- Ejemplo: Sea E = 5.
  - Representar 3 en exceso: 3 + 5 = 8
  - Representar -4 en exceso: -4 + 5 = 1
  - Interpretar 2 (expresado en exceso): 2 5 = -3
- Al contrario de BCS, Ca1 y Ca2; Ex2 NO sigue la regla del bit más significativo

Esta técnica simplemente desplaza todos los números representables en función el exceso E definido.

En Ex2 binario, **E** está definido por **2**<sup>n-1</sup>, donde **n** es el número de bits.

#### Ejemplos:

- Si n=3  $\rightarrow$  E =  $2^{3-1}$  = 4
- Si n=4  $\rightarrow$  E =  $2^{4-1}$  = 8
- Si n=8  $\rightarrow$  E =  $2^{8-1}$  = 128

- Si n=3  $\rightarrow$  E =  $2^{3-1}$  = 4
- Si n=4  $\rightarrow$  E =  $2^{4-1}$  = 8
- Si n=8  $\rightarrow$  E =  $2^{8-1}$  = 128

Ejemplos **acotado a 4 bits**. El valor resultante luego de aplicar el exceso se escribe en BSS. La interpretación al leer un número expresado en exceso se hace en BSS.

- Expresar 1 en Exceso:  $1 + 8 = 9 \rightarrow 1001_2$
- Expresar 3 en Exceso:  $3 + 8 = 11 \rightarrow 1011_2$
- Expresar -2 en Exceso:  $-2 + 8 = 6 \rightarrow 0110_2$
- Interpretar  $0000_2$  expresado en Exceso:  $0 8 = -8 \rightarrow -8$
- Interpretar 1111, expresado en Exceso:  $15 8 = 7 \rightarrow 7$
- Interpretar  $1000_2$  expresado en Exceso:  $8 8 = 0 \rightarrow 0$


Dado que **Ex2 simplemente transporta los números representables a un intervalo diferente** de la recta numérica, es posible representar la misma cantidad de números distintos que combinaciones posibles de bits.

- Ejemplo: Con 8 bits se pueden realizar 256 combinaciones.
- En Ex2 con 8 bits se pueden representar 256 números distintos.
- No presenta el problema del doble cero como Ca1 y BCS.
- A diferencia de BCS y Ca1, **Ex2 maximiza** la capacidad de representación en función del número de combinaciones posibles.

#### Resumen de sistemas

Secuencia de bits	<b>BSS</b> Nros: 2 <sup>n</sup> Rango: 02 <sup>n</sup> -1	<b>BCS</b> Nros: 2 <sup>n</sup> -1 Rango: -(2 <sup>n-1</sup> -1)2 <sup>n-1</sup> -1	<b>Ca1</b> Nros: 2 <sup>n</sup> -1 Rango: -(2 <sup>n-1</sup> -1)2 <sup>n-1</sup> -1	<b>Ca2</b> Nros: 2 <sup>n</sup> Rango: -(2 <sup>n-1</sup> )2 <sup>n-1</sup> -1	<b>Ex2</b> Nros: 2 <sup>n</sup> Rango: -(2 <sup>n-1</sup> )2 <sup>n-1</sup> -1
000	0	0	0	0	-4
001	1	1	1	1	-3
010	2	2	2	2	-2
011	3	3	3	3	-1
100	4	-0	-3	-4	0
101	5	-1	-2	-3	1
110	6	-2	-1	-2	2
111	7	-3	-0	-1	3

#### Resumen de sistemas




# Temas de la segunda parte

- Representación de datos
- Números enteros
- Operaciones aritméticas ←
- Punto fijo
- Punto flotante


#### Operaciones aritméticas

- La ALU realiza operaciones lógicas y aritméticas.
- Recibe los operandos y la operación a realizar
- Devuelve el resultado y las bits de condición (flags)



#### Operaciones aritméticas.

Las sumas y restas en binario son similares que en decimal. "Me llevo uno" y "le pido al compañero" siguen vigentes.





¿Qué son los flags?

Son bits que el procesador establece de modo automático acorde al resultado de cada operación realizada.

Sus valores permitirán tomar decisiones como:

- Realizar o no una transferencia de control.
- Determinar relaciones entre números (mayor, menor, igual).

• **Z** (zero): vale 1 si todos los bits del resultado de una operación son cero

$$0010$$
  $0001$   $0001$   $0001$   $0001$   $0000$ 

Es de utilidad para - por ejemplo - realizar comparaciones por igualdad.

Si quiero comparar la igualdad de 2 variables A y B; simplemente puedo restar ambos valores, y si el flag de Z es 1, entonces son iguales.

• N (negativo): vale 1 si el bit más significativo del resultado también es 1.

Es de utilidad para - por ejemplo - realizar comparaciones por desigualdad.

Si quiero comparar la desigualdad de 2 variables A y B; simplemente puedo restar A-B, y si el flag de N es 1, entonces B es mayor que A.

Solo es de utilidad su análisis si estamos trabajando en un sistema con signo.

- C (carry): flag de acarreo
  - vale 1 si en una suma hay acarreo del bit más significativo
  - o vale 1 si en una resta hay 'borrow' hacia el bit más significativo

Sirve para determinar si no se puede representar el resultado de la operación con el número de bits utilizado, principalmente en BSS.



¿Qué ocurre si sumamos 1?

- V (overflow): flag de desbordamiento: Indica una condición fuera de rango en Ca2. Casos:
  - Si sumamos 2 positivos y el resultado es negativo
  - Si sumamos 2 negativos y el resultado positivo
  - o Si a un positivo le restamos un negativo el resultado es negativo
  - o Si a un negativo le restamos un positivo el resultado es positivo

```
1000
+ 1010
----
0010 \rightarrow V = 1
1000
- 0001
0111 \rightarrow V = 1
```

Sirve para determinar si no se puede representar el resultado de la operación con el número de bits utilizado en sistemas con signo, ppalmente Ca2.

Tanto **C** (para BSS) como **V** (para Ca2) implican errores de desbordamiento debido a que el resultado **no puede ser representado con el número de bits** que se está utilizando.

**Se requieren más bits** para representar el resultado de manera correcta en el sistema dado.


Veamos a continuación algunos **ejemplos**. En todos los casos se realiza primero la operación matemática binaria a nivel de bits, se determinan los flags y **recién luego se interpretan los valores** en los sistemas de representación.



Los dos resultados son correctos



Ca2 incorrecto, BSS correcto



Ca2 correcto, BSS incorrecto

	Operación	NZVC	Cal	2 BSS
	1001	0011	<b>-</b> 7	9
+	1100		<b>+</b> -4	<b>+</b> 12
	0101		5	5


Ambos resultados incorrectos

# Operaciones aritméticas. Flags aritméticos

	Operación	NZVC	Cal	2 BSS
	0101	1001	5	5
-	0111		<b>-</b> 7	<b>-</b> 7
	1110		-2	14

Ca2 correcto, BSS incorrecto

# Operaciones aritméticas. Flags aritméticos



Ca2 incorrecto, BSS correcto

# Operaciones aritméticas. Flags aritméticos

#### Recordar:

Las operaciones sobre bits son **siempre las mismas** sin importar el sistema de representación utilizado. Ejemplo:  $1_2 + 1_2 = 10_2$  siempre.

La CPU recibe los operandos y operación a realizar, para luego devolver el resultado y flags sin importar el sistema de representación utilizado.

El análisis de uno u otro flag será de utilidad dependiendo el tipo sistema en el que están representados los valores.

Ejemplo: No es de utilidad analizar los flags V o N si estamos representando números en BSS.

## Errores de desbordamiento "famosos"


#### Pac-Man Kill Screen Bug

Al llegar al nivel 255 del pacman, caos total en pantalla.

- 1. LD A, (#4E13): Load 255 into A
- 2. INC A: Increment 255 to 256 this overflows to 0
- 3. CP #08: Is 0 less than 8? Yes.
- 4. JP NC, #2C2E: Don't jump to large-number fruit handling code
- 5. LD DE, #3B08: Load the address of the cherry into DE
- 6. Start the fruit-drawing loop

https://retrocomputing.stackexchange.com/questions/1640/why-does-the-kill-screen-glitch-occur-in-pac-man http://www.gamasutra.com/view/feature/3938/the pacman dossier.php?print=1

El código no contempla la posibilidad de que al llegar al nivel 255 y sumar 1, el contador de niveles (un dato de 8 bits únicamente), desborda a 0. Esto hace que el render del nivel se comporte de manera errática.



## Errores de desbordamiento "famosos"


#### Gandhi ultraviolento en Civilization

Gandhi fue un pacifista, pero en el juego Civilization declaraba la guerra y atacaba otras civilizaciones con bombas nucleares.

Motivo: todos los líderes del juego poseen un **nivel de agresión**. Gandhi por ser pacifista se le asignó el menor valor posible entre todos los líderes: 1.

Pero si un jugador adopta la democracia, el nivel de agresión se reduce en **2 unidades** para todos los líderes.

Esto genera un underflow no contemplado del valor de la agresión a 255!



https://kotaku.com/why-gandhi-is-such-an-asshole-in-civilization-1653818245

## Errores de desbordamiento "famosos"

#### Gangnam Style INT\_MAX overflow

Alojaba el número de reproducciones en contador de 32 bits.

 $2^{32}$  = 4.294.967.296 números, de los cuales la mitad son positivos y la mitad negativos, con lo cual el rango comprende los valores -2.147.483.648 y 2.147.483.647

Alcanzada la reproducción 2.147.483.647+1, el contador de desborda a -2.147.483.648.

Resuelto al convertir el tipo de dato a 64 bits. Nuevo desborde al alcanzar 9.223.372.036.854.775.807 (9 trillones) de visitas.



# Temas de la segunda parte

- Representación de datos
- Números enteros
- Operaciones aritméticas
- Punto fijo ←
- Punto flotante

En los sistemas de punto fijo, se considera que todos los números a representar tienen exactamente la misma cantidad de dígitos y la coma fraccionaria está siempre ubicada en el mismo lugar.

Por ejemplo, en sistema decimal: 0,23; 5,12; 9,11

En cada caso, los números tienen tres dígitos, y la coma está a la derecha del más significativo

En sistema binario es el mismo concepto: 11,10; 01,10; 00,11

Hay 4 dígitos y la coma está entre el segundo y tercer dígito.

La diferencia principal entre la representación en el papel y su almacenamiento en computadora, es que no se guarda coma alguna, se supone que está en un lugar determinado.

## Rango y resolución

Rango: para un sistema de representación dado, el **rango** contempla el intervalo de valores representable entre el mayor y el menor de éstos

Resolución: para un sistema de representación dado, la **resolución** es la diferencia mínima posible entre dos números consecutivos

Para el ejemplo anterior en sistema decimal:

- Rango es de 0,00 a 9,99 o bien [0,00 .. 9,99]
- Resolución es 0,01: 2,32 2,31 = 0,01 o bien 9,99 9,98 = 0,01

Si desplazamos la coma dos lugares a la derecha:

- Rango es de 0 a 999 o bien [0 .. 999]
- Resolución es 1: 3 2 = 1 o bien 999 998 = 1

→ Notar que hay un compromiso entre rango y resolución ←

En cualquiera de los casos hay **10**<sup>3</sup> números distintos: El número de combinaciones entre los dígitos **es siempre la misma** más allá de la posición de la coma decimal.

<u>Binario</u>	<u>Decimal</u>
0000	0
0001	1
0010	2
0011	3
0100	4
0101	5
0110	6
0111	7
1000	8
1001	9
1010	10
1011	11
1100	12
1101	13
1110	14
1111	15

4 bits parte entera0 bits parte fraccionaria

Rango: 0 .. 15 Resolución: 1

<u>Binario</u>	<u>Decimal</u>
000,0	0
000,1	0,5
001,0	1
001,1	1,5
010,0	2
010,1	2,5
011,0	3
011,1	3,5
100,0	4
100,1	4,5
101,0	5
101,1	5,5
110,0	6
110,1	6,5
111,0	7
111,1	7,5

3 bits parte entera1 bit parte fraccionaria

Rango: 0 .. 7,5 Resolución: 0,5

Binario	Decimal
00,00	0
00,01	0,25
00,10	0,5
00,11	0,75
01,00	1
01,01	1,25
01,10	1,5
01,11	1,75
10,00	2
10,01	2,25
10,10	2,5
10,11	2,75
11,00	3
11,01	3,25
11,10	3,5
11,11	3,75

2 bits parte entera2 bits parte fraccionaria

Rango: 0 .. 3,75

Resolución: 0,25

<u>Binario</u>	Decimal
0,000	0
0,001	0,125
0,010	0,25
0,011	0,375
0,100	0,5
0,101	0,625
0,110	0,75
0,111	0,875
1,000	1
1,001	1,125
1,010	1,25
1,011	1,375
1,100	1,5
1,101	1,625
1,110	1,75
1,111	1,875

1 bits parte entera3 bits parte fraccionaria

Rango: 0 .. 1,875

Resolución: 0,125

<u>Binario</u>	<u>Decimal</u>
,0000	0
,0001	0,0625
,0010	0,125
,0011	0,1875
,0100	0,25
,0101	0,3125
,0110	0,375
,0111	0,4375
,1000	0,5
,1001	0,5625
,1010	0,625
,1011	0,6875
,1100	0,75
,1101	0,8125
,1110	0,875
,1111	0,9375

0 bits parte entera4 bits parte fraccionaria

Rango: 0 .. 0,9375

Resolución: 0,0625

Si todos los bits se encuentran asignados a la parte fraccionaria, el sistema nunca llegará a representar el número 1 decimal, incluso con una gran cantidad de bits.

```
,111111<sub>2</sub>
                                       0,984375
Con 6 bits →
                  ,11111112
                                       0,991875
Con 7 bits →
                  ,11111111
Con 8 bits →
                                       0,99609375
                  ,111111111,
                                       0,998046875
Con 9 bits →
                  ,1111111111
                                       0,999023438
Con 10 bits →
                  ,11111111111
                                       0,999511719
Con 11 bits →
```

Cada bit fraccionario adicional está sumando <u>la mitad del bit inmediato más</u> <u>significativo</u>. De esta manera, el sistema representará números entre 0 y "casi 1".

Al convertir un número decimal a sistema binario tendremos 2 casos:

☐ Sin restricción en la cantidad de bits a usar:

$$3,0078125_{10} = 11,0000001_{2}$$

Con restricción, por ejemplo 3 bits para parte entera y 4 bits para parte fraccionaria:

$$\Box 3,125_{10} = 011,0010_{2}$$

En este caso, el número de bits disponible es suficiente para representar el número.

En una computadora, la capacidad de representación de un número estará dada por el tipo de dato que es utilizado para representar a dicho número.

#### Error absoluto y relativo

En ciertos casos, no es posible representar el número exacto, debiendo representar el valor más cercano posible.

# **Error Absoluto (EA)**: es la diferencia absoluta entre el valor representado y el valor que se deseaba representar


El EA máximo será siempre menor o igual a la mitad de la resolución del sistema: en el peor de los casos el número a representar se encuentra justo en la mitad de dos números representables consecutivos dentro del sistema utilizado.

#### Error Relativo (ER): = EA / Número a representar

El ER es un coeficiente que denota la incidencia del error de representación sobre el número representado ¿cuán importante es el error?

Error absoluto (EA). Ejemplo: representar 3,2<sub>10</sub> con distintas restricciones en el número de bits.

- 3 bits para parte fraccionaria:  $011,010_2 = 3,25_{10}$ 
  - $\circ$  Error = 3,2 3,25 = -0,05
- 4 bits para parte fraccionaria: 011,0011<sub>2</sub> = 3,1875<sub>10</sub>
  - $\circ$  Error = 3,2 3,1875 = 0,0125
- 5 bits para parte fraccionaria: 011,00111<sub>2</sub> = 3,21875<sub>10</sub>
  - $\circ$  Error = 3,2 3,21875 = -0,01875
- 6 bits para parte fraccionaria: 011,001101<sub>2</sub> = 3,203125<sub>10</sub>
  - $\circ$  Error = 3,2 3,203125 = -0,003125



0,01875

El **EA** más pequeño es **0,003125** entonces **3,203125** es la representación más cercana a **3,2** dentro de este ejemplo. Con más bits asignados a la parte fraccionaria, sería incluso posible reducir más el error.

**Error relativo (ER)** = EA / Número a representar

#### Ejemplo:

- Se desea representar el 1,5 pero solo es posible representar el 1,10
  - $\circ$  EA = | 1 1,5 | = 0,5
  - o ER = 0,5 / 1,5 = **0,333**
  - El error representa un 33,3% con respecto del valor que se deseaba representar
- Se desea representar el 1.000.000,5<sub>10</sub> pero solo es posible representar el 1.000.000<sub>10</sub>
  - EA = | 1.000.000 1.000.000,5 | = **0,5**
  - o ER = 0,5 / 1.000.000,5 = **0,0000005**
  - El error representa un 0,00005% con respecto del valor que se deseaba representar

#### Para ambos casos el EA es el mismo, sin embargo, el ER es:

- Considerable en el primero
- Despreciable en el segundo (para la mayoría de los dominios tradicionales de la computación general).

# Temas de la segunda parte

- Representación de datos
- Números enteros
- Operaciones aritméticas
- Punto fijo
- Punto flotante ←

En punto fijo es posible representar un rango de valores positivos y negativos centrados en 0.

Sin embargo, punto fijo tiene limitaciones: números "muy grandes" y números "muy pequeños" en un mismo sistema:



CPU Intel i386 junto al co-procesador matemático de punto flotante i387 DX

- Tamaño de un átomo:
  - o 0,0000000002 metros
- 1 googol:

Notación científica es de utilidad en estos casos:

Un número decimal "muy grande": 976.000.000.000.000
 se puede representar como: 9,76 x 10<sup>14</sup>

Un número decimal "muy pequeño": 0,0000000000000976
 se puede representar como: 9,76 x 10<sup>-14</sup>

Hemos desplazado en forma dinámica la coma decimal a una posición conveniente y usar el exponente de base 10 para definir la ubicación de la coma.

Esto permite tener un rango de números desde "muy pequeños" a "muy grandes" y pueden ser representados con pocos dígitos.

Este mismo enfoque puede ser aplicado para representar números binarios.

Un número se puede representar de la forma: ± M x B <sup>±E</sup>

Este número se puede almacenar en una palabra binaria con los dos campos **M** (mantisa) y **E** (exponente), los cuales pueden estar representados en cualquiera de los sistemas ya vistos (BSS, BCS, Ca1, Ca2, Ex2).

La mantisa **M** puede incluso ser fraccionaria.

La base **B** es implícita y no necesita almacenarse.

→ Se necesitan menos bits para almacenar **M** y **E** que el número completo. ←

Un posible formato para almacenar un número en punto flotante:

Exponente (Ca2 8 bits) Mantisa (BCS 24 bits)

La ubicación del exponente y de la mantisa, así como el número de bits asignados y los sistemas de representación utilizados son parte de la definición del sistema de punto flotante dado.

## Ejemplo:

- Mantisa
  - o BSS
  - 4 bits
  - Entera
- Exponente
  - o BSS
  - 4 bits
  - Entera

## Ejemplo:

- Mantisa
  - o BSS
  - o 4 bits
  - Entera
- Exponente
  - o BSS
  - o 4 bits
  - Entera

- Nro Máximo:  $1111 \times 2^{1111} = 15 \times 2^{15}$
- Nro Mínimo: 0
- Rango:  $[0 ... 15 \times 2^{15}] = [0 ... 491520]$
- Resolución extremo inferior:  $(1 0) \times 2^0 = 1$
- Resolución extremo superior:  $(15 14) \times 2^{15} = 2^{15}$

Contrastemos con sistema punto fijo 8 bits BSS:

- Rango: [0 .. 255]
- Resolución extremo inferior: 1
- Resolución extremo superior: 1


### Ejemplo:

- Mantisa
  - o BSS
  - 4 bits
  - Entera
- Exponente
  - o BSS
  - o 4 bits
  - Entera

Si comparamos ambos sistemas vemos:

- El rango en punto flotante es mayor
- La cantidad de combinaciones binarias distintas es la misma en ambos sistemas: 2<sup>8</sup> =256
- En punto flotante la resolución no es constante a lo largo del intervalo, como lo es en el ejemplo de punto fijo.
- En punto flotante "Ganamos" rango, "resignando" resolución con respecto a punto fijo.

En punto flotante la posición de los valores no es uniforme a lo largo de la recta de números representables (como lo es en punto fijo), con lo cual existe una resolución distinta en cada uno de los extremos.



## Ejemplo:

- Mantisa
  - o Ca2
  - o 4 bits
  - Entera
- Exponente
  - o Ca2
  - 4 bits
  - Entera

## Ejemplo:

- Mantisa
  - o Ca2
  - o 4 bits
  - Entera
- Exponente
  - o Ca2
  - o 4 bits
  - Entera

- Nro Máximo: 0111 x  $2^{0111}$  = 7 x  $2^{7}$
- Nro Mínimo:  $1000 \times 2^{0111} = -8 \times 2^7$
- Rango:  $[-8 \times 2^7 ... 7 \times 2^7] = [-1024 ... 896]$
- Resolución extremo inf (pos):  $(1 \times 2^{-8} 0) = 0,0390625$
- Resolución extremo sup (pos):  $(7 6) \times 2^7 = 2^7 = 128$

## Ejemplo:

#### Mantisa

- o BCS
- o 24 bits
- o Fracc.

## Exponente

- o Ca2
- o 8 bits
- o Entera

FORMATO DEL EJEMPLO				
Exponente	Mantisa Fraccionaria			
SEEEEEE	1/21/41/8 SMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMMM			
S = bit de signo E = bits magnitud	S = bit de signo M = bits de magnitud (fraccionarios)			
	Primer bit M tiene una magnitud de ½ Segundo bit M tiene una magnitud de ¼ Tercer bit M tiene magnitud de ½			

### Ejemplo:

- Mantisa
  - o BCS
  - o 24 bits
  - o Fracc.
- Exponente
  - o Ca2
  - o 8 bits
  - Entera

El rango es simétrico dado que la mantisa es BCS.

$$= (2^{-1} + 2^{-2} + 2^{-3} + \dots 2^{-21} + 2^{-22} + 2^{-23}) \times 2^{127}$$

- $\circ$  = (1-2<sup>-23</sup>) x 2<sup>127</sup> = 0,999999881 x 1,701411835×10<sup>38</sup>
- o = 170.141.163.300.000.000.000.000.000.000.000.000
- Nro mínimo positivo: 000000000000000000001 x 2<sup>10000000</sup>
  - $\circ$  = 2<sup>-23</sup> x 2<sup>-128</sup> = 2<sup>-151</sup>
- Nro máximo negativo: 1000000000000000000001 x 2<sup>10000000</sup>
  - $\circ$  = -2<sup>-23</sup> x 2<sup>-128</sup> =2<sup>-151</sup>

$$= -(2^{-1} + 2^{-2} + 2^{-3} + \dots 2^{-21} + 2^{-22} + 2^{-23}) \times 2^{127}$$

- $\circ$  = -(1-2<sup>-23</sup>) x 2<sup>127</sup> = -0,999999881 x 1,701411835×10<sup>38</sup>
- o = -170.141.163.300.000.000.000.000.000.000.000.000

# Punto flotante. Normalización

Veamos el siguiente problema:

$$40 \times 10^{0} = 4 \times 10^{1} = 0.4 \times 10^{2} = 400 \times 10^{-1} = 40$$
 en todos los casos

Existen distintos valores de mantisa y exponente para representar un mismo número.

Lo mismo sucede en base 2.

Con el objetivo de tener un único par de valores de mantisa y exponente para un número, se introduce la normalización.

## Punto flotante. Normalización

La normalización binaria es el proceso de mover el punto fraccionario de manera tal que el bit más significativo después del punto (sin considerar el bit de signo) sea 1. Esto es:

Donde S es el bit de signo (si corresponde) y M son los restantes bits de la mantisa.

Esto implica además que la mantisa normalizada tendrá siempre una magnitud de al menos ½.

## Punto flotante. Normalización

Ejemplo de normalización. Mantisa fraccionaria 4 bits BSS. Exponente BSS 3 bits.

$$0010 \times 2^{010} = \frac{1}{8} \times 2^2 = 0.5 \leftarrow \text{No está normalizada!}$$

Debemos correr los bits de la mantisa 2 posiciones hacia la izquierda, pero además **debemos compensar con el exponente** para mantener el mismo valor del número (0,5). Para ésto, **se decrementa** en 2 unidades el valor del exponente.

$$1000 \times 2^{000} = \frac{1}{2} \times 2^0 = 0.5 \leftarrow \text{Si está normalizada}$$

#### Recordar:

- Al correr hacia la izquierda los bits de la mantisa, estoy multiplicando por 2
- Al decrementar en una unidad el valor del exponente, estoy dividiendo por 2

## Punto flotante. Bit implícito.

Todo número en punto flotante normalizado comienza con 1 (representando ½). ¿es necesario almacenar el 1?

Si no lo almacenamos, ganamos un bit para representar números con mayor precisión:

Donde M es el nuevo bit que podemos adicionar a la magnitud de la mantisa.

Notar que el bit más significativo adiciona a la magnitud ¼ en lugar de ½

Al igual que las mantisas fraccionarias normalizadas, las mantisas fraccionarias normalizadas con bit implícito **siempre tienen una magnitud mínima de 0,5**.

## Punto flotante. Bit implícito.

Mantisa fraccionaria normalizada BCS 4 bits, exponente BSS 2 bits. ¿nro máximo?

$$\frac{1}{2}\frac{1}{4}\frac{1}{8}$$
  
0 **1** 1 1 x 2<sup>11</sup> = 0**1**11x2<sup>11</sup> = (**2**<sup>-1</sup> + 2<sup>-2</sup> + 2<sup>-3</sup>) x 2<sup>3</sup> = 0,875 x 2<sup>3</sup> = 7

Mantisa fraccionaria **normalizada** con bit implícito BCS 4 bits, exponente BSS 2 bits. ¿nro máximo?

$$\frac{1}{2}\frac{1}{4}\frac{1}{8}\frac{1}{16}$$
  
0 **4** 1 1 1 x 2<sup>11</sup> = 0111x2<sup>11</sup> (2<sup>-1</sup> + 2<sup>-2</sup> + 2<sup>-3</sup> + 2<sup>-4</sup>) x 2<sup>3</sup> = 0,9375 x 2<sup>3</sup> = 7,5

¿Cómo representar el 0 en este sistema? NO SE PUEDE

## Punto flotante. Errores de representación.

Punto flotante presentará errores de representación para ciertos números "difíciles" de representar en un espacio acotado de bits (por ejemplo, números recurrentes):

```
wsuario@pc-usuario: ~

usuario@pc-usuario: ~$ python

Python 2.7.12 (default, Nov 12 2018, 14:36:49)

[GCC 5.4.0 20160609] on linux2

Type "help", "copyright", "credits" or "license" for more information.

>>> 1+2

3

>>> .1+.2

0.300000000000000004

>>> □
```


$$0.1_{10} = 0.0001100\overline{1100}...$$
  $0.2_{10} = 0.00110011\overline{0011}...$ 

https://www.exploringbinary.com/why-0-point-1-does-not-exist-in-floating-point/http://effbot.org/pyfaq/why-are-floating-point-calculations-so-inaccurate.htm/https://stackoverflow.com/questions/588004/is-floating-point-math-broken

## Punto flotante. Errores de representación. Ejemplo

1991 Patriot missile failure due to magnification of roundoff error







R-17 (SS-1C Scud-B)

Patriot Radar System

MIM-104 Patriot Missile

# Punto flotante. Errores de representación. Ejemplo

1991 Patriot missile failure due to magnification of roundoff error

- Software desarrollado en assembler 20 años antes. Modificado varias veces para la guerra del Golfo Pérsico (operation Desert Storm) para poder interceptar misiles balísticos de alta velocidad.
- Registro de valores de tiempo transcurrido desde el instante de inicio del sistema en décimas (0.1d) de segundo, acotado a 24 bits.
- Problema de representación:

- Introducción de subrutina para convertir mediciones de tiempo en punto flotante con mayor precisión
- La invocación a esta subrutina era necesaria en varias partes del código, pero dichas invocaciones no se realizaron en todas las ubicaciones donde se requería.
- Luego 100 horas de up-time del sistema Patriot: 0.3433 segundos de error (tiempo en el que un Scud atraviesa 500 metros aproximadamente).
- Saldo: 28 soldados fallecidos

Standard establecido por la IEEE (Institute of Electrical and Electronics Engineers) en el año 1985 para cómputo en punto flotante.

Ampliamente utilizado en varios dominios de la computación (aunque no en todos, dadas las limitaciones de precisión en punto flotante).

Tanto software como hardware "hablan el mismo idioma" en lo que refiere a representación de números en punto flotante.



Ejemplo en Java:

```
float a = 3.14; \rightarrow 32-bit IEEE-754 (simple precision) double b = 6.022e23; \rightarrow 64-bit IEEE-754 (double precision)
```

Las variables **a** y **b** serán representadas por una secuencia de bits según el standard.

Esta secuencia de bits es "entendida" entonces tanto por el software como por el hardware.


#### El standard define:

- Formatos numéricos
  - De qué manera estructurar la secuencia de bits a fin de representar números
- Operaciones
  - De tipo aritméticas, trigonométricas, etc.
- Reglas de redondeo
  - A fin de aproximar al valor más cercano representable mediante redondeos o truncamientos.
- Manejo de excepciones
  - Ante la presencia de situaciones inesperadas como división por cero


Entre otros, define los siguientes formatos:

#### Simple precisión (32 bits)

#### Doble precisión (64 bits)



### Cuádruple precisión (128 bits)



### Formato numérico (introducción):

- Mantisa:
  - o BCS
  - Fraccionaria normalizada con la coma después del primer bit que es siempre uno (1,)
- Exponente:
  - o Representado en exceso <u>sesgado</u>: 2<sup>n-1</sup>-1
- Casos especiales

```
\circ E = 111..111<sub>2</sub> M <> 0 \rightarrow NaN
```

$$\circ$$
 E = 111..111<sub>2</sub> M = 0  $\rightarrow$  Infinito

$$\circ$$
 E = 0 M = 0  $\rightarrow$  Cero

$$\circ$$
 E = 0 M <> 0  $\rightarrow$  Denormalizado (0,)

### Máximo valor representable simple precisión:


$$2^{128} \approx 3.40 \times 10^{38} \approx$$

## Máximo valor representable doble precisión:


$$2^{1024} \approx 1,79 \times 10^{308} \approx$$


## IEEE 754. Simple vs doble precisión.

El trade-off con la precisión persiste



## IEEE 754. Simple vs doble precisión. Ejemplo.





https://blog.codinghorror.com/why-do-computers-suck-at-math/

## IEEE 754. Simple vs doble precisión. Ejemplo.

Google pareciera estar utilizando **simple precisión** (32 bits) en lugar de **doble precisión** (64 bits) Si cambiamos **float** por **double** la precisión se incrementa y el resultado es el esperado.

https://www.lnds.net/blog/lnds/2008/8/25/por-que-falla-la-calculadora-de-google

# IEEE 754. Aplicación interactiva.

			IEEE 7	754 Converter (JavaScript), V0.22	
	Sign	Exponent		Mantissa	
Value:	+1	2-126 (denormalized)		0.0 (denormalized)	
Encoded as:	0	0		0	
Binary:		00000			
	You entered		0		
	Value actually stored in float:		0		+1
	Error due to conversion:		0		-1
	Binary Representation		000000000000000000000000000000000000000		
	Hexadecimal Representation		0x0000000		

https://www.h-schmidt.net/FloatConverter/IEEE754.html