CONCEPTOS DE BASES DE DATOS

CLASE 6

Árboles

Resumen

- Un árbol binario se desbalancea fácilmente

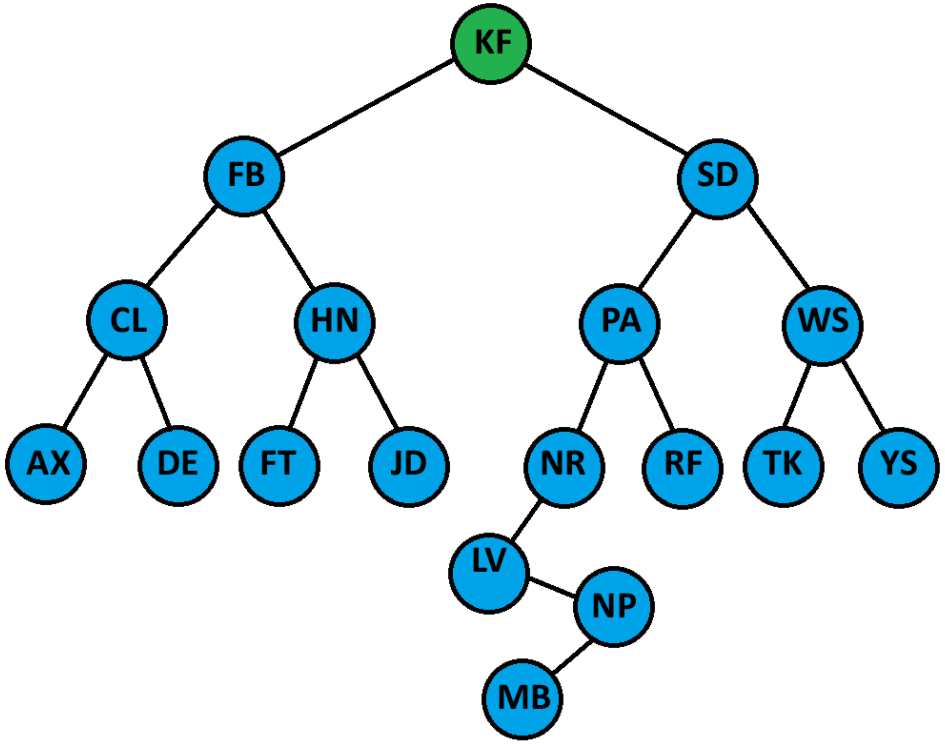

Árboles

Resumen

- Los árboles balanceados en altura proporcionan una solución aceptable al problema de mantener un índice ordenado
  - Los cambios son locales (no masivos)
- Pero como son árboles binarios, son muy profundos al usarlos con muchos elementos
  - Para 1.000.000 claves, un árbol AVL puede tener 28 niveles → demasiado

Árboles

Resumen

- Los árboles binarios paginados introducen la idea de agrupar claves en páginas, pero no se ha encontrado la forma de hacerlo eficientemente

- Problemas

  - ¿Cómo construirlo?
  - ¿Cómo elegir la raíz?
  - ¿Cómo mantenerlo balanceado?

Árboles

Resumen

- Los árboles multicamino son una buena opción que resuelve uno de los problemas que tienen los árboles binarios → cantidad de niveles

- Para asegurar que las búsquedas realizadas tengan un costo logarítmico → se debe asegurar que el árbol esta balanceado

Árboles

Resumen

- Árboles B (orden M)
  - Son árboles multicamino
  - Se construyen en forma ascendente → se mantiene balanceado a bajo costo
  - Cantidad de hijos por nodo:
    - Mínimo: [M/2] hijos (menos raíz y terminales)
    - Máximo: M hijos
  - Nodos terminales al mismo nivel
    - Mínimo: [M/2]-1 claves
    - Máximo: M-1 claves

Árboles

Resumen

- Árboles B
  - Inserción: si el nuevo registro produce overflow
    - **División del nodo**. Promoción. puede propagarse hasta generar una nueva raíz.
  - Eliminación: si el nodo queda en underflow
    - **Redistribución**. Alguno de sus nodos adyacentes hermanos tiene elementos suficientes → se realiza la redistribución entre dicho nodo y el que quedó en underflow.
    - **Concatenación**. Ninguno de sus nodos adyacentes hermanos tiene elementos suficientes → se realiza la concatenación entre uno de ellos y el que quedó en underflow. Es posible perder un nivel del árbol.

Árboles

Resumen

- **Inserción vs Eliminación**

?	⟺	Redistribución
División	⟺	Concatenación

  - La redistribución podría posponer la creación de nuevos nodos
  - Se pueden generar árboles B más eficientes en términos de utilización de espacio

Árboles

Balanceados (B*)

- Árbol B*: Es un **árbol B especial** en el que cada nodo está lleno por lo menos en 2/3 partes (excepto la raíz)
- Propiedades de un árbol B* de orden M
  - **Cantidad de hijos por nodo**:
    - Máximo: M hijos
    - Mínimo: [(2M – 1) / 3] hijos (menos raíz y terminales)
    - Mínimo raíz: 2 hijos (o sino ninguno)
  - **Nodos no terminales**: K hijos → K-1 claves
  - **Nodos terminales (hoja)**: todos están al mismo nivel
    - Máximo: M-1 claves
    - Mínimo: [(2M – 1) / 3]-1 claves

Árboles

Operaciones (B*)

- **Búsqueda**: similar a árbol B
- **Inserción**: redistribución / división. Tres políticas:
  - Derecha (de un lado):
    - Redistribuir con nodo adyacente hermano derecho (o izq. si es el último). Si esta lleno se realiza la división **usando ambos nodos**.
  - Derecha o Izquierda (de un lado u otro)
    - Si el nodo derecho está lleno, se intenta hacerlo con el izquierdo. Si ambos están llenos **se usa el nodo en overflow y su hermano derecho** para realizar la división.
  - Derecha e Izquierda (de un lado y otro)
    - Similar anterior, pero al realizar la división **se usan los tres nodos**, generando cuatro nodos que tendrán 3/4 parte llena.
- **Eliminación**: similar a árbol B (redist./concat.)

Árboles

Balanceados

- Manejo de nodos (páginas) en buffers
  - Objetivo: minimizar cantidad de accesos a disco
  - El SO administra gran cantidad de buffers
    - Buffers más usados → se mantienen en RAM
    - Estrategias de reemplazo: **LRU** (Least Recently Used)
    - Tamaño buffer → capacidad del nodo
  - Si se almacenan nodos en un **buffer en RAM**
    - Sólo el nodo raíz → se ahorra 1 acceso a mem. secundaria
    - Nodo raíz y otros principales → se ahorran varios accesos a memoria secundaria

Árboles

Balanceados

- Manejo de nodos (páginas) en buffers → Ej.
  - Cantidad de claves = 2400
  - Cantidad de nodos = 140
  - Altura del árbol = 3

Cantidad de páginas en buffers en RAM	1	5	10	20
Cantidad de accesos promedio por búsqueda	3	1.71	1.42	0.97

Árboles

Balanceados

- Conclusiones
  - Los árboles balanceados B y B* permiten el acceso aleatorio por clave de forma eficiente
  - Además, los árboles B* exigen que sus nodos se mantengan más llenos que los árboles B → menor altura
  - Pero si se debe realizar un **procesamiento secuencial ordenado por clave** utilizando este tipo de árboles, ¿se puede realizar de forma eficiente?

Árboles

Balanceados

- Archivos secuenciales indizados
  - Permiten dos formas de acceso:
    - **Indizado**: acceso aleatorio por clave
    - **Secuencial**: acceso secuencial ordenado por clave
  - Alternativas de implementación con los métodos vistos hasta ahora:
    - **Orden físico**: ineficiente al sufrir modificaciones
    - **Árbol B**: rápida recuperación para acceso aleatorio pero ineficiente para acceso secuencial
  - Es necesaria una solución que permita ambos accesos de forma eficiente → Árboles B+

Árboles

Balanceados (B+)

- Los árboles B+ constituyen una mejora sobre los árboles B
  - Conservan la propiedad de acceso aleatorio rápido de los árboles B (acceso indizado)
  - Permiten además un recorrido secuencial ordenado rápido

Árboles

Balanceados (B+)

- Un árbol B+ consta de dos partes
  - Índice → nodos interiores
    - En la raíz y nodos interiores **se duplican las claves** necesarias para definir los caminos de búsqueda
  - Secuencia → nodos hojas enlazados
    - Todas las claves se encuentran en los nodos hoja
    - Los nodos hoja están vinculados → se obtiene una **trayectoria secuencial** para recorrer las claves del árbol

Árboles

Balanceados (B+)

- Propiedades de un árbol B+ de orden M
  - **Cantidad de hijos por nodo**:
    - **Máximo**: M hijos
    - **Mínimo**: [M/2] hijos (menos raíz y terminales)
    - **Mínimo raíz**: 2 hijos (o sino ninguno)
  - **Nodos no terminales (interiores)**
    - Son punteros a los datos → no contienen datos
  - **Nodos terminales (hoja)**: todos están al mismo nivel
    - Representan un conjunto de datos y son linkeados juntos

Árboles

Balanceados (B+)

- Comparación

ÁRBOL B

ÁRBOL B+

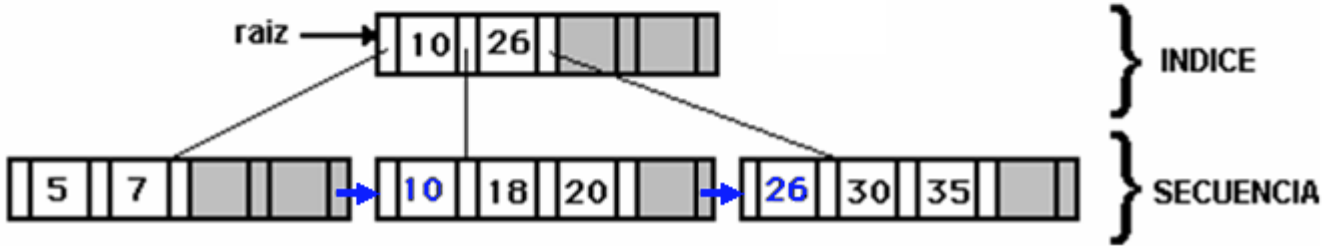

Árboles

Balanceados (B+)

- Un árbol B+ ocupa más espacio que un árbol B equivalente, ya que además de las claves contiene las claves separadores

- Las claves del nodo raíz y nodos interiores se utilizan únicamente como índice para las búsquedas

Árboles

Operaciones (B+)

- **Búsqueda**
  - No debe detenerse cuando se encuentre la clave en la **raíz** o en un **nodo interior**
  - La búsqueda continúa por el nodo apuntado por la **rama derecha** de dicha clave hasta llegar a un nodo hoja
  - Si se llega a un nodo hoja sin éxito → la clave no se encuentra en el archivo

Árboles

Operaciones (B+)

- **Inserción**
  - Es **similar a la de los árboles B**, excepto cuando se desea insertar una clave en donde el nodo se encuentra lleno
  - En ese caso, el **nodo lleno se divide** en otros dos, pero ahora:
    - El primero contendrá M/2 claves
    - El segundo 1+M/2 claves, ya que lo que subirá al padre será una copia de la clave central

Árboles

Operaciones (B+)

- **Inserción** (orden M = 5)

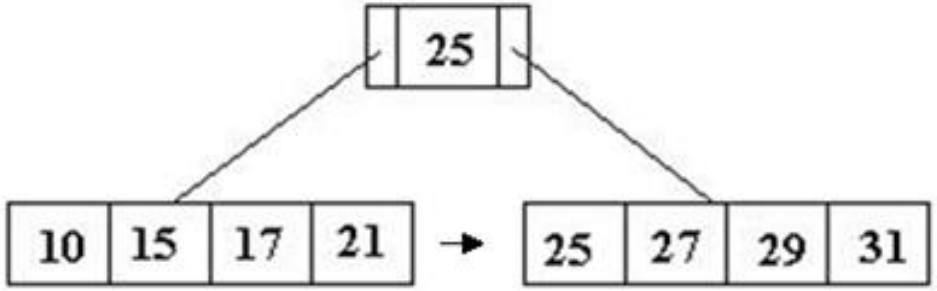

AL INSERTAR LA CLAVE 13:

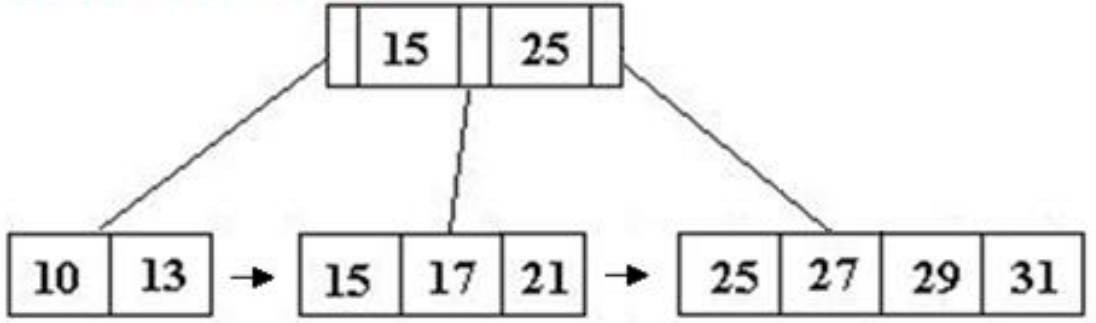

Árboles

Operaciones (B+)

- **Eliminación**
  - Todas las claves se encuentran en los nodos hoja → más simple que en los árboles B
  - Si al eliminar no se produce underflow
    - Las claves de la raíz o nodos internos **no se modifican** ya que siguen siendo un separador válido entre las claves de los nodos descendientes
  - Si al eliminar se produce underflow
    - Es necesario una redistribución o fusión de las claves, que involucra a las hojas y el índice

Árboles

Operaciones (B+)

- **Eliminación** (orden M = 6)

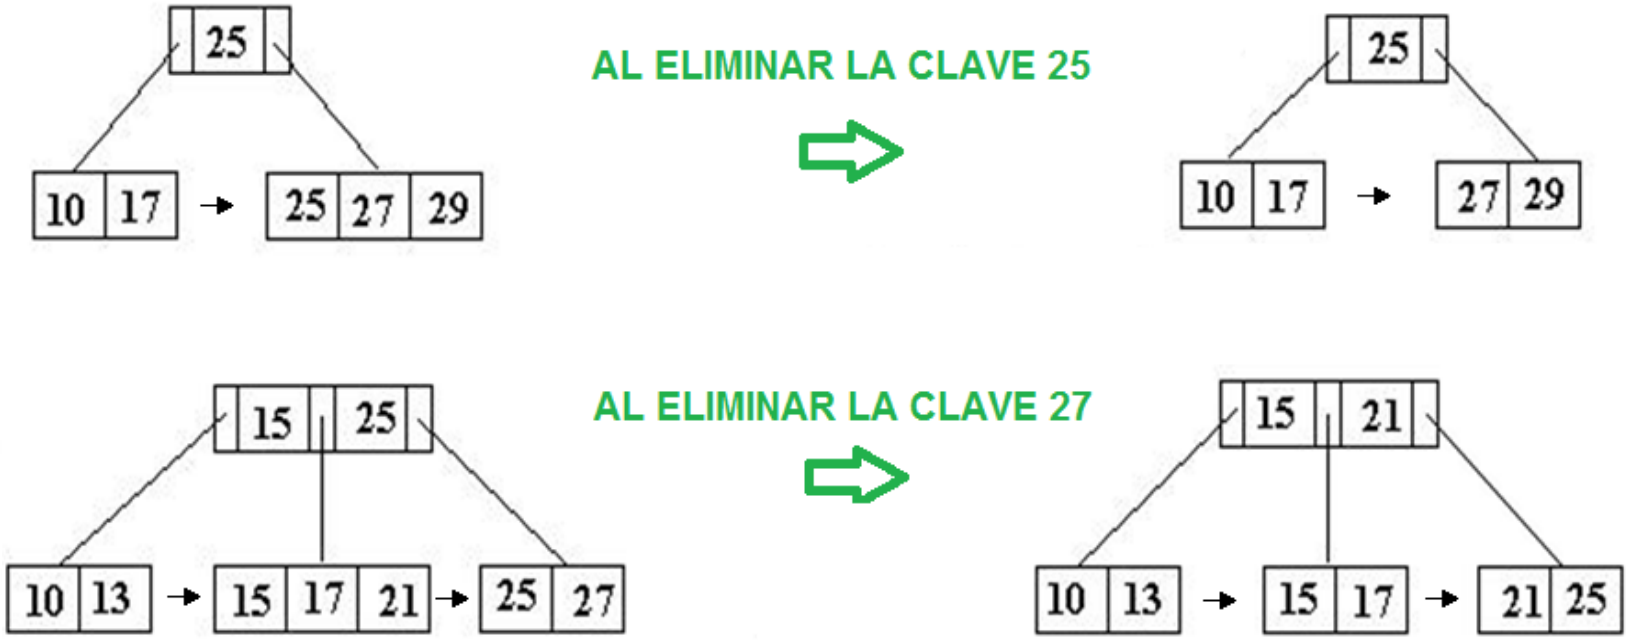

Árboles

Operaciones (B+)

- **Eliminación** (orden M = 6)

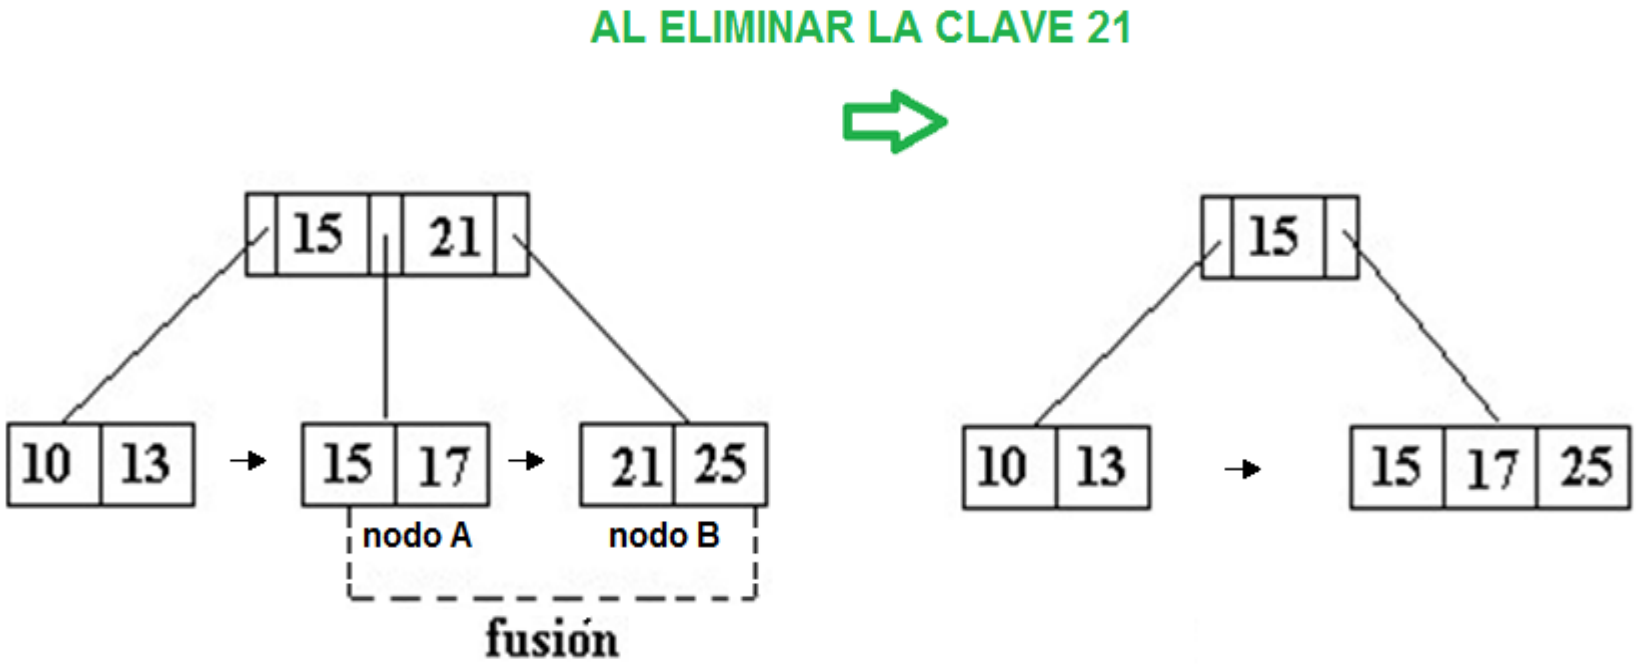

Árboles

Balanceados (B+)

- **Separadores**
  - Son derivados de las claves de los registros que limitan un bloque en el conjunto de secuencia
  - Separadores más cortos → ocupan espacio mínimo
- **Árbol B+ de prefijos simples**
  - Es un árbol B+ en el cual el conjunto índice está constituido por separadores más cortos

Árboles

Balanceados (B+)

- **Árbol B+ de prefijos simples**

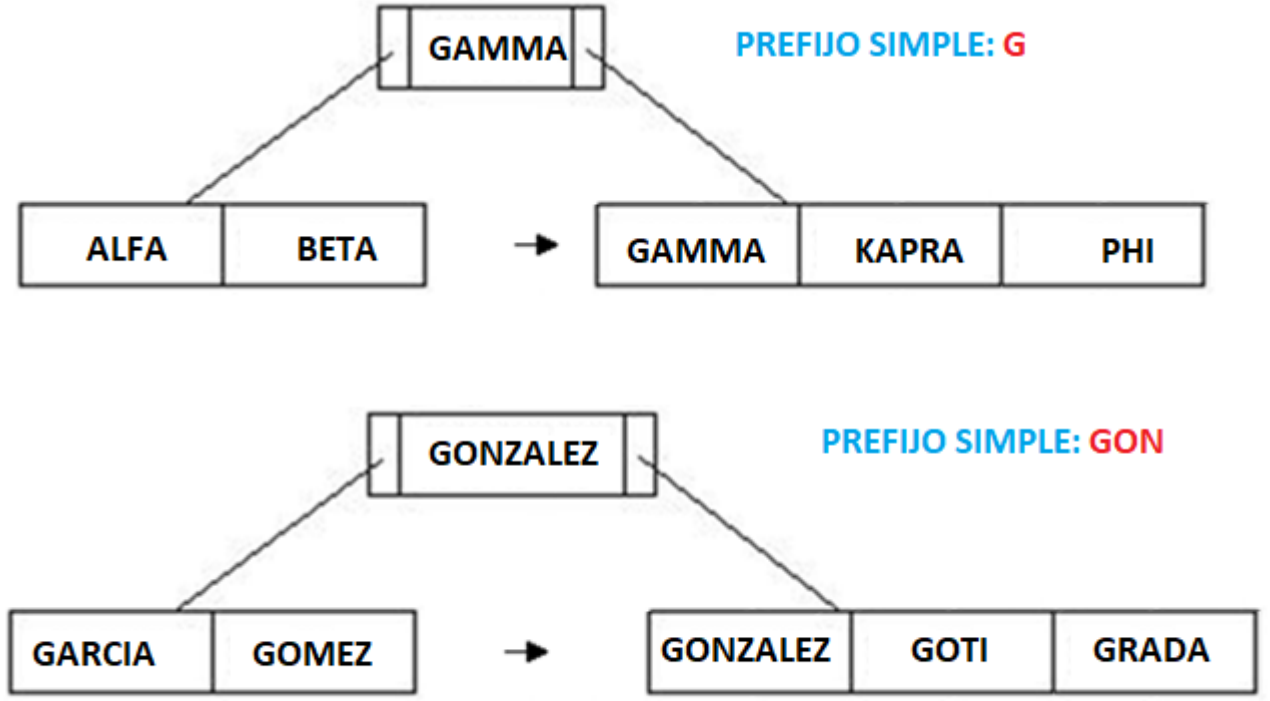

Árboles

Balanceados

- **Comparación**

	Árbol B	Árbol B+
Ubicación de datos	Nodos (cualquiera)	Nodos terminales
Tiempo de búsqueda	Equivalente (puede ser algo mejor)	Equivalente
Procesamiento secuencial ordenado	Lento (complejo)	Rápido (con punteros)
Inserción/Eliminación	Equivalente	Equivalente