

Definir sistema paralelo

Un sistema paralelo es la combinación entre un software paralelo y una arquitectura paralela sobre la que se implementa.

Software paralelo(algoritmo paralelos): varias unidades de procesamiento cooperan para resolver un problema, con el objetivo de mejorar el rendimiento de la solución secuencial.

Arquitectura paralela(hardware paralelo): arquitectura con múltiples unidades de procesamiento que permiten el procesamiento en paralelo de software paralelo.

Definir multiprocesador, multicore, manycore y clúster.

Multiprocesador: más de una unidad de procesamiento

Multicore: una unidad de procesamiento o cpu que en un mismo circuito integrados incorpora dos o más unidades de procesamiento/ejecución conocidos como cores o núcleos.

manycore: arquitecturas que poseen un gran número de cores simples.

Cluster: son varias máquinas interconectadas mediante una red de comunicación que se comporta como si fuese una única máquina permitiendo mayor potencia de cómputo.

Explicar el principio de localidad y cómo se aplica a la multiplicación de matrices.

El principio de localidad se divide en dos tipos:

- Localidad temporal: establece que los datos recientemente utilizados tienden a volver a utilizarse en un futuro cercano.
- Localidad espacial: establece que si se accede a un dato, es probable que también se acceda pronto a datos que se encuentran en posiciones de memoria cercanas.

Este principio es fundamental en el diseño y uso de memorias caché, ya que permite anticipar accesos y traer bloques de datos que aumentan la eficiencia al reducir los tiempos de acceso a memoria.

En la multiplicación de matrices $A \times B$ cada elemento de la matriz resultado se obtiene multiplicando una fila de A por una columna de B:

- Para la matriz A: sus elementos se almacenan en memoria de manera contigua por filas (en el esquema *row-major* típico). Por lo tanto, al recorrer una fila se aprovecha la localidad espacial, generando pocos *cache misses*.
- Para la matriz B: se necesitan sus columnas, pero estas no están almacenadas de forma contigua en memoria. Esto provoca más *cache misses* y un acceso ineficiente.

Una solución común es trasponer la matriz B antes de la multiplicación, de modo que las columnas originales se conviertan en filas contiguas en memoria. Así, al recorrerlas se mejora la localidad espacial y se reducen los fallos de caché.

Describir la etapa de descomposición según lo planteado por Ian Foster

La descomposición según Foster(teoría 1):

- Particionado: que parte del trabajo se puede hacer en paralelo dividiendo el trabajo.



- Comunicación: determinar los patrones de comunicación entre las tareas vistas en el paso previo.
- Aglomeración: combinar las tareas y la comunicación en los pasos anteriores, en tareas de mayor tamaño para adaptarlas a nuestro hardware paralelo
- Mapeo: asignar cada tarea a un procesador para maximizar la utilización del mismo y reducir la comunicación.

Enumerar las estrategias del Ananth Grama.

Estrategias de Ananth Grama(Teoría 5 página 15):

- Descomposición recursiva.
- Descomposición basada en datos.
- Descomposición exploratoria.
- Descomposición especulativa.
- Descomposición híbrida.

Es un mismo problema puede haber más de una estrategia de descomposición.

Estrategias de Ananth Grama(Teoría 5 página 63):

- Mapeo estático: las tareas se dividen en unidades de procesamiento antes de la ejecución.
- Mapeo dinámico: las tareas se dividen en unidades de procesamiento durante la ejecución.

La verdad no sé a qué estrategias hace referencia la pregunta.

Determinar la mejor descomposición para una multiplicación de matrices.

La mejor descomposición para la multiplicación de matrices es la descomposición en bloques 2D, ya que a cada procesador se le asigna un bloque de las matrices de entrada para calcular el bloque correspondiente de la matriz resultado. Esto evita que cada procesador tenga que acceder a la matriz completa, como ocurriría en la descomposición por filas o por columnas, donde se requiere replicar una de las matrices en todos los nodos.

La descomposición por elementos, si bien es conceptualmente paralela, exigiría tener tantas unidades de procesamiento como elementos de la matriz, lo cual no es práctico y además genera un gran overhead de comunicación y sincronización.

En cambio, la descomposición por bloques logra un buen equilibrio: aprovecha la localidad temporal y espacial en memoria, reduce el número de accesos a memoria principal y disminuye los fallos de caché. Además, facilita el balance de carga entre procesadores y permite una mejor escalabilidad del algoritmo.

Determinar si la multiplicación de matrices es vergonzosamente paralela.

La multiplicación de matrices no es un problema vergonzosamente paralelo, ya que este término se aplica únicamente a aquellos problemas cuyas tareas son totalmente independientes, sin necesidad de comunicación ni intercambio de datos entre sí.

En el caso de la multiplicación de matrices, cada elemento de la matriz resultado CCC se obtiene combinando una fila de AAA con una columna de BBB. Esto implica que los

distintos procesos deben compartir acceso a los mismos datos (filas y columnas), lo cual introduce comunicación y sincronización.

Por lo tanto, si bien la multiplicación de matrices es altamente paralelizable, no puede considerarse vergonzosamente paralela.

Definir los siguientes conceptos: speedup, speedup ideal, speedup superlineal, eficiencia, ley de Amdahl, ley de Gustafson.

Speedup: es una métrica de rendimiento que representa el beneficio relativo alcanzado al ejecutar del programa.

$$S = \frac{T_s}{T_p} \quad \begin{cases} T_s : & \text{tiempo de ejecución secuencial,} \\ T_p : & \text{tiempo de ejecución paralelo con } \mathbf{P} \text{ unidades de procesamiento.} \end{cases}$$

Speedup lineal: se obtiene cuando el speedup es igual a las unidades de procesamiento.

Speedup superlineal: es cuando el speedup es mayor a las unidades de procesamiento.

Eficiencia: es una métrica de rendimiento que indica el porcentaje de tiempo que las unidades de procesamiento están haciendo trabajo útil.

Ley de Amdahl: indica que existe una parte del programa no paralelizable que limita el speedup máximo que se puede conseguir para un tamaño fijo.

ley de Gustafson: a medida que aumentamos el tamaño del problema la parte “inherentemente secuencial” del problema disminuye en tamaño y es posible alcanzar un speedup mayor.

9. Especifique en que sección de la tabla se aplica la la ley de Amdahl y en cual la ley de Gustafson.

comm_sz	Order of Matrix				
	1024	2048	4096	8192	16,384
1	1.0	1.0	1.0	1.0	1.0
2	1.8	1.9	1.9	1.9	2.0
4	2.1	3.1	3.6	3.9	3.9
8	2.4	4.8	6.5	7.5	7.9
16	2.4	6.2	10.8	14.2	15.5

Para analizar la tabla con las leyes pedidas:

- Ley de Amdahl: se observan las columnas. Por ejemplo, en la columna de tamaño 2048 se mantiene fijo el problema y se analiza cómo varía el *speedup* al aumentar la cantidad de procesadores.

- Ley de Gustafson: se observan las filas. Allí se mantiene fija la cantidad de procesadores y se analiza cómo varía el *speedup* al aumentar el tamaño del problema.