




P = 8

▨ → cuantos cores habilitamos = $\frac{P}{4}$

2.1 Una GPU ejecuta problemas donde existe poca o nula dependencias entre los datos, los problemas considerados embarrassingly Parallel. Algunos ejemplos de estos pueden ser la multiplicación de matrices, el procesamiento de gráficos y otros problemas numéricos (Procesamiento de señales).

La GPU utiliza un mecanismo de control SIMD, más específicamente SIMT, donde múltiples hilos ejecutan la misma instrucción de forma sincronizada.

El modelo de comunicación es de memoria compartida, todas las UPs acceden a una misma memoria principal (Device memory o HBM).

3 Las 4 etapas de Diseño de un Programa Paralelo son:

1 Etapa de descomposición o Particionamiento: En esta etapa se descompone el problema en tareas. Se busca que estas tareas sean de gran variedad fino, para flexibilizar el diseño en las etapas posteriores.

2 Etapa de comunicación: En esta etapa se define que se debe comunicar entre tareas y de que forma se va a hacer. Se define la topología, si será estructurada o no, si es sincrónica o no, unidireccional o bid, ...

3 Etapa de Aglomeración: se busca combinar las tareas definidas en

1 en tareas de mayor tamaño con 3 objetivos en mente:

- Reducir el overhead de comunicación
- Mantener la escalabilidad
- Cuestiones adicionales de ing. software (mantenimiento).

4 Etapa de mapeo: se busca asignar las tareas a las unidades UP (hilos o procesos, que estas ejecutan) de forma tal de maximizar la utilización, obtener un buen balance de carga y minimizar el overhead de comunicación. Se podría agregar tradeoff de sistema híbrido.

EX(1) Podría agregar que la comunicación es una característica inherente a los programas paralelos.

3.1) las estrategias de descomposición se dividen en funcional, por datos, exploratoria y especulativa:

- funcional: Se divide el Problema en tareas o etapas. (ej: un Pipeline gráfico).
- Por datos: se dividen los datos del problema en múltiples subconjuntos a los que se les aplica el mismo o un cómputo similar. la división se puede aplicar a los datos de entrada, salida o intermedios.
- exploratoria: Se Recorre un espacio de búsqueda y se generan tareas dinámicamente, ejemplo: Reinas.
- especulativa: el Problema consiste en etapas (Paralelizables) donde la etapa a ejecutar próximamente depende de un resultado previo. Se realiza una predicción de la próxima etapa a ejecutar.

ERRORES: los tipos de descomp son en datos o funcional, pero las estrategias son las que palse pero con recursiva en lugar de funcional. *1

¿Que se Paraleliza aquí? las "etapas" son tareas?

Para la multi de matrices es conveniente la descomp de datos de salida, ya que los procesamientos asignados a cada subconjunto son completamente independientes entre si.

4) El Speedup es una métrica que mide el beneficio relativo obtenido al ~~Realizar~~ una mejora u optimización

Ejecutar un programa

↳ En el speedup Paralelo, la mejora consiste en la Paralelización del Problema.

$$S = \frac{T_a}{T_b} \rightarrow \text{en el caso de speedup Paralelo es}$$

$$S = \frac{T_s}{T_p(CP)}$$

ABSOLUTO: si es el mejor secuencial conocido.
Relativo: si no es el mejor sec conocido
 $S = \frac{T_p(1)}{T_p(CP)}$

Speedup SUPERLINEAL: Speedup donde $S(P) > P$, caso poco probable en la Práctica pero puede ocurrir, debido a:

- mejor localidad de cache en ejecución Paralela
- Diferente carga de trabajo (Poda de un BB debido a interacción comunicada por otra tarea)
- cuestiones de compilación.

hasta una gran variedad donde es mas conveniente computar que seguir reduciendo.

*1 - D. Recursiva: es la estrategia de tipo de descomposición donde se divide el problema en sus problemas de forma recursiva (dividir = tareas), luego se computa y por ultimo se combinan o Reducen estos resultados (combinar = reducir).