

Sistemas Distribuidos y Paralelos

Ingeniería en Computación



Arquitecturas Paralelas Evolución y tendencias

Universidad Nacional de La Plata



Facultad de Informática





1

Evolución de las arquitecturas paralelas

2

Paralelismo en procesadores monocore

3

Multiprocesadores

4

Clusters

5

Multicores

Simétricos. Asimétricos.

6

Grid

7

Manycores

8

FPGAs

9

Cloud computing

10

Computación cuántica

11

Paralelismo en otros dispositivos

12

Estado actual, tendencias y expectativas futuras




1

Evolución de las arquitecturas paralelas

Evolución de las arquitecturas paralelas

4



A dark, atmospheric photograph of a vintage computer room. In the foreground, an open, old book with yellowed pages lies on a dark, textured surface. Behind it, a stack of papers and a small, glowing computer monitor are visible. The background is filled with rows of vintage computer equipment, with warm, orange lights emanating from various components, creating a bokeh effect. A desk lamp with a white shade is visible in the upper left, casting a soft light. The overall mood is nostalgic and focused on early computing technology.

2

Paralelismo en procesadores monocore

Paralelismo en monoprocesadores


6

- 1940-1950: Computadoras a válvulas
- 1947: Transistor reemplaza las válvulas
- 1960: Técnicas para mejorar el rendimiento:
 - Paralelismo a nivel de instrucción (ILP)
 - Planificación dinámica
 - Tomasulo **1967** implementado en IBM360/91 de **1964**
- 1970: Circuitos integrados



Procesador o CPU: hardware encargado de ejecutar instrucciones y coordinar operaciones, integrando toda su funcionalidad en un único circuito integrado (microprocesador)

Procesador moncore o Monoprocesador: Procesador o CPU que posee una única unidad de procesamiento dentro del circuito integrado y que ejecuta un solo flujo de instrucciones a la vez.






Multiprocesadores

Monocores y concepto SMP

- La posibilidad de agregar más de un procesador o CPU
- 1950-1980: equipos muy costosos y voluminosos
- 1990-2000: Multiprocesadores a menor costo y en circuitos integrados
- Sistema de memoria:
 - Acceso compartido a memoria
 - Memoria cache por procesador
 - Problemas de coherencia



Multiprocesador moncore: Sistema de cómputo que posee dos o más monoprocesadores independientes, que comparten la memoria principal y los recursos del sistema, permitiendo la ejecución concurrente de múltiples flujos de instrucciones.

Multiprocesamiento Simétrico (SMP) moncore: Organización de sistemas multiprocesador en la que todos los monoprocesadores son iguales.

Multiprocesadores

Primeras propuestas e ideas

1957 – Gamma 60

Compañía Bull SAS (París - Francia)

- Primera computadora Multihilo diseñada específicamente para paralelismo
- 25 unidades de procesamiento a 100Khz
- 96KB de memoria central
- Modelo Fork-Join
- Distribuidor de programas que envía y recopila datos hacia y desde unidades de procesamiento independientes conectadas a una memoria central.

Ideas de la época

- 1958:
 - Gill discutió la Programación Paralela y la espera
 - Cocke y Slotnick discutieron por primera vez el uso del paralelismo en cálculo numérico
- 1962 – D825: Primer máquina con Crossbar Switch:
 - 4 Unidades de procesamiento a 16 módulos de memoria
- 1967 – Ley de Amdhal:
Conferencia de la Federación Estadounidense de Sociedades de Procesamiento de Información
- 1969 – Sistema Multics de HoneyWell con 8 procesadores

Paper de Tumlin

Paper de Bataille

Sitio WEB de Smotherman



Multiprocesadores

Primeras propuestas e ideas

10

1971 - C.mmp (Multi-Mini-Processor)

Carnegie Mellon University (CMU)

- MIMD
- 16 procesadores (PDP-11)
 - 8KB de memoria por procesador
- Un único espacio de direcciones
- Un bus de control
- Crossbar switch para conectar procesadores y memoria
- Sistema operativo Hydra
 - Implementado en Bliss (Carnegie Mellon University - 1970)
 - Microkernel orientado a objetos (POO tiene su origen en Simula62)




Fig. 1. The C.mmp multiprocessor.

[Paper de Bell \(CMU\)](#)

[Sitio WEB de Bosworth](#)



1976 – ILLIAC IV

Lawrence Livermore National Laboratory (LLNL)

- Primer SIMD.
- Proceso de fabricación muy demorado (11 años) que llevo a que ILLIAC IV fuera superado por las primeras computadoras comerciales (Cray-1)

1976 – CRAY-1

Cray Research (EEUU)

- Primer procesador secuencial Vectorial
- Procesador de 64-bit a 80 MHz
- 8MB de memoria





Clusters

12

Cluster: Varias computadoras, conocidas como nodos, interconectadas mediante una red de comunicación que se comportan como si fuesen una única máquina, formando una arquitectura de memoria distribuida y permitiendo mayor potencia de cómputo.

Proyecto ARPANET: primera red entre cuatro centros informáticos

1969

1977

1983

1984

1989

Protocolos y herramientas para trabajo remoto facilitan la distribución y el uso compartido de archivos (BSD Unix y Sun Microsystems).

ARCnet (Datapoint): Primer cluster comercial sin éxito.

VAXcluster: Clúster con cierto éxito
sistema operativo VAX/VMS

Bajos costos - PVM – TCP/IP
Popularidad de clusters

Red de comunicación

Nodo

Memoria

Nodo

Memoria

Nodo


Memoria

...

Clusters

Algunas características

- Dos tipos de clusters:
 - Alto rendimiento (Orientado a HPC)
 - Alta disponibilidad (Orientado a servicio)
- Según uniformidad:
 - Homogéneos: todas las máquinas iguales
 - Heterogéneos: máquinas difieren en varios niveles (HW, SO, compiladores, red etc.)
- **Desventajas:**
 - Mayor posibilidad de **fallas**.
 - **Latencia** en las comunicaciones: debido a capas de protocolo en entornos LAN. Puede reducirse con redes de alta velocidad (infiniband, myrinet).
 - **Gestión** y administración **compleja**.
- Es posible conectar varios clusters formando una arquitectura **multicluster**.
- Requiere de **programación distribuida**.





5

Multicores

Simétricos.


Asimétricos.

Multicores

15

-  **Siglo XX:** cada nueva generación de procesadores moncore superaba en velocidad a la anterior.
- **Siglo XXI:** incrementar la velocidad requiere mas energía y se genera mas calor.
 - Calor difícil de disipar y mayor consumo de energía.
 - Último monoprocesador de Intel: Pentium IV a aprox. 4Ghz.
- Fin a la era monoprocesadores y comienzo de la era multicore.

Procesador multicore: Procesador o CPU que, en un mismo circuito integrado, integra dos o más unidades de procesamiento independientes, conocidas como núcleos o cores, que comparten la memoria principal y los recursos del sistema, permitiendo la ejecución concurrente de múltiples flujos de instrucciones.





Multicores

Multiprocesadores multicore

16

- Actualmente, hasta 4 CPUs o Procesadores multicore en una máquina

Multiprocesador multicore: Sistema de cómputo que posee dos o más procesadores multicore independientes, que comparten la memoria principal y los recursos del sistema, permitiendo la ejecución concurrente de múltiples flujos de instrucciones, tanto entre procesadores como entre cores de un mismo procesador.



Motherboard con soporte para 4 CPUs o Procesadores
Cada CPU o Procesador tiene 6 cores

- Dos tipos de procesadores multicore:
 - **Simétricos:** Cores idénticos.
 - **Asimétricos:** Cores diferentes.
- Ambas ideas surgen casi al mismo tiempo.
 - Primera generación simétrica.
 - Posteriormente también asimétricos.



5

Multicores

Simétricos.

Asimétricos.

Multicores simétricos

Concepto SMP moderno

19

- Cores en Multicores simétricos:
 - Misma arquitectura.
 - Mismas capacidades.
 - Para cualquier tipo de tarea.
- **Redefinición de SMP** (*Symmetric Multiprocessing*):

Multiprocesamiento Simétrico (SMP) multicore: Organización de sistemas multiprocesador en la que todos los cores de todos los procesadores son iguales.

- Máquina con uno o varios procesadores con cores iguales: organización SMP.



Multicores simétricos

Primeros multicores de Intel

20

Año	Microarquitectura	Nombre comercial	Características
2005	NetBurst	Pentium D	Dos chips Pentium IV encapsulados
2006	Dual Core	Dual Core	Dos cores de 32 bits en un único chip
2007	Core 2	Core 2 Duo (2 cores) Core 2 Quad (4 cores)	Evolución de Dual Core Tecnología 64 bits

- **2007-2016:** estrategia *Tick-Tock* de Intel:
 - **Tick:** “Contracción” de la arquitectura del proceso de microarquitectura anterior.
 - **Tock:** Creación de una nueva microarquitectura.
- Otras tecnologías adicionales:
 - Hyperthreading
 - Turboboost
 - Varios niveles de memoria cache



Multicores simétricos

Evolución Intel


21

Nanotecnología: manipulación de la materia a escala nanométrica.


$1 \text{ nanómetro} = 10^{-9} \text{ metros}$

$1 \text{ Angstrom} = 0,1 \text{ nanómetro} = 10^{-10} \text{ metros}$


Nanotechnology



Influenza virus



Bohr Radius
0,59 Angstrom





Multicores simétricos

Evolución Intel


22

Basados en BUS

Intel® Xeon® Processor 5300 Series
Intel® Core™ Microarchitecture




Harpertown




Basados en Crossbar


Nehalem



Barcelona (AMD)



Skylake-Broadwell (Cache L4 - 64MB/128MB)




Multicores simétricos

Evolución Intel

23

Microarquitectura Ivy bridge 22nm Placa gráfica On-Chip


3rd Generation Intel® Core™ Processor:
22nm Process



New architecture with shared cache delivering more performance and energy efficiency

Quad Core die with Intel® HD Graphics 4000 shown above
Transistor count: 1.4Billion Die size: 160mm²
** Cache is shared across all 4 cores and processor graphics

Microarquitectura Skylake 14nm Procesador gráfico avanzado




Multicores simétricos

Evolución Intel

24

- Fin del proceso *Tick-Tock* en 14nm.
- **2016** - Nuevo proceso de fabricación de tres pasos (**PAO**):
 - **Process:** Igual Tick
 - **Architecture:** Igual Tock
 - **Optimization:** Optimización de la arquitectura
- Tres generaciones en un sólo proceso de manufactura.
- Dos líneas:
 - Pentium/Core
 - Atom



Multicores simétricos

Evolución Intel

25

Línea (Pentium/Core)	Proceso	Microarquitectura	Código	Generación	Año
Tock	14nm	Sky Lake		6, 7, 8 y 9	2015-2019
P rocess	10nm	Palm Cove	Cannon Lake	8	2018
A rchitecture		Sunny Cove	Ice Lake	10	2019
O ptimization		Willow Cove	Tiger Lake	11	2020
		7nm Intel 7	Golden Cove	Alder Lake	12
	Raptor Cove		Raptor Lake	13	2022
P rocess	5nm Intel 4	Redwood Cove	Meteor Lake	14	2023
A rchitecture		?	?		
O ptimization		?	?		
P rocess	2nm Intel 20A	Lion Cove	Arrow Cake	15	2024
A rchitecture		?	Lunar Lake	16	2024
O ptimization		?	?		
P rocess	Intel 18A	TBA	Phanter Lake		2025
A rchitecture		?	Diamond Rapids		2026
O ptimization	TSMC	?	Nova Lake		2026

Multicores simétricos

Evolución Intel

26

Línea (Atom)	Proceso	Microarquitectura	Año
Tock	14nm	Goldmont	2016
P rocess	10nm	Tremont	2020
A rchitecture	7nm Intel 7	Gracemont	2021
O ptimization	Intel 3	Crestmont	2023/2024
P rocess	TSMC N3B	Skymont	2024
A rchitecture	Intel 18A	Darkmont	2026

Tremont: Primer Procesador Híbrido de Intel



5

Multicores

Simétricos.

Asimétricos.

¿Por qué tener cores iguales?



- **Especialización:** procesadores específicos eficientes para ciertos tipos de tareas.



Multicores Heterogéneos

Heterogéneos pp.


- Compilar código para cada tipo de core

Asimétricos

- Misma ISA (Instruction Set Architecture)
- Una única compilación de código

- **2003 - Propuesta de Kumar:**

- Pocos **Big** (o Fast) **cores**: complejos, potentes, alto consumo de energía.
- Varios **Small** (o Slow) **cores**: simples, poco potentes, bajo consumo de energía.



- Diferentes tipos de cores, usarlos de acuerdo a las distintas demandas computacionales de las aplicaciones, con el objetivo de lograr mayor rendimiento por watt.

Multicores asimétricos

Concepto AMP

29

- Concepto de AMP (*Asymmetric Multiprocessing*):



Multiprocesamiento Asimétrico (AMP) multicore: Organización de sistemas multiprocesador, con un mismo conjunto de instrucciones (ISA), compuesta por cores distintos que se adaptan a las diferentes fases de ejecución de una aplicación.

- Máquina con uno o varios procesadores, con algunos cores diferentes pero misma ISA: organización AMP.
 - Ejemplo: **QuickIA de Intel.**



Multicores asimétricos

ARM big.LITTLE


30

- **2014** – Primera microarquitectura asimétrica comercial: **ARM big-LITTLE** (ARM Holding - Cambridge – Inglaterra).
- Dos tipos de core:
 - **BIG Cores:** mayor rendimiento y mayor consumo (Ej: ARM Cortex A15, A55, A73)
 - **Little Cores:** menor rendimiento y menor consumo (Ej: ARM Cortex A7, A53)
- big.LITTLE en dispositivos móviles System-on-Chips (SoCs) ARM desarrollados por Samsung Electronics:




2018 - Samsung Exynos serie 7885

- Procesador ARM Cortex-A73 (2 cores 2.2GHz)
- Procesador ARM Cortex-A53 (6 cores 1.6GHz)



2020 - Samsung Exynos serie 900

- Procesador Samsung Exynos M5 (2 cores 2.73GHz)
- Procesador ARM Cortex-A76 (2 cores 2.5GHz)
- Procesador ARM Cortex-A55 (4 cores 2GHz)



Multicores asimétricos


ARM big.LITTLE

31

Disposiciones de cores ARM big.LITTLE


Cluster

- Cores en cluster.
- Requerimientos por mayor potencia activa cluster Big.
- Requerimientos por menor potencia activa cluster Small.
- Simultáneo sólo 4 cores (Big o Small).




In Kernel switcher

- Virtual core: un Big y un Small.
- Requerimientos por mayor potencia activa virtual core Big.
- Requerimientos por menor potencia activa virtual core Small.
- Simultáneo sólo 4 cores.



Heterogeneous multi-processing

- Cores individuales.
- Requerimientos requieren migraciones de hilos o procesos.
- Simultáneo 8 cores.



Multicores asimétricos

Intel

32

- **2020 – Primer asimétrico comercial de Intel:** Lakefield penta-core, para móviles, microarquitectura Tremont.
- Dos tipos de core:
 - **E-Cores** (*Efficient cores*): *simil Little Cores*. Maximizar el rendimiento por watt.
 - Microarquitectura Tremont (0.8Ghz – 2.8Ghz).
 - **P-Cores** (*Performance cores*): *simil BIG Core*. Cómputo de alto rendimiento.
 - Microarquitectura Sunny Cove – Alder Lake (1.4Ghz – 3.0Ghz).
- 2021 - otros asimétricos para equipos de escritorio:

Procesador	E-Cores	P-Cores
Core i9 (12900K)	8 (2.4Ghz – 3.9Ghz)	8 (3.2Ghz – 5.1Ghz)
Core i7 (12700T)	4 (1.0Ghz – 3.4Ghz)	8 (1.4Ghz – 4.6Ghz)





Multicores asimétricos

CPU + GPU + NPU


33

- **2023:** procesadores Intel de arquitectura Meteor Lake (generación 14) con un diseño más complejo con tres tipos de capacidades de cómputo:
 - **CPU:** Multicore
 - **GPU:** Placa gráfica
 - **NPU (Neural Processing Unit):** redes neuronales (IA)
- **AMD** comercializa un procesador similar, Ryzen serie 7040 (Zen 4), que incluyen la llamada Ryzen AI.






Grid Computing: Sistema que permite compartir y coordinar recursos de cómputo distribuidos geográficamente para resolver problemas que requieren gran capacidad de procesamiento.



- Proyectos:
 - CETI (1999 – California University, Berkeley)
 - EELA (2006 – CERN - Comisión Europea – América Latina)
 - CYTED (2006 – Iberoamérica)
 - Rosetta@home (2020 - BOINC)
- Gestión de recursos mediante *Middleware* (**Overhead**):
 - Globus toolkit (2004 - 2018)
 - Glite (Branch de Globus Toolkit version 2 – 2005 – 2013)
 - BOINC (California University, Berkeley - 2002)





- **1980-1990:** Placas gráficas para acelerar procesamiento gráfico y así liberar a la CPU.
- **1990-2000:** GPU (*Graphics Processing Unit*)
- **2006:** Placas Nvidia con procesadores programables
 - Uso para propósito general (mayor rendimiento – menor consumo energético).
 - Concepto **GPGPU** (*General-Purpose computing on Graphics Processing Units*)

GPGPU: Concepto según el cual se desarrollan aplicaciones de propósito general sobre unidades de procesamiento gráfico (GPUs).


- Dos empresas líderes:
 - Nvidia
 - AMD (compró ATI en 2006)

Manycores

Arquitecturas Nvidia y AMD


38

Arquitectura NVidia



Cores dispuestos en Mallas/Grillas.
Jerarquía de memoria compleja.

Arquitectura AMD ATI



Manycores Arquitectura Nvidia

39

- Modelos PCI express
- Arquitectura Ada Lovelace: 18432 CUDA Cores + 576 Tensor cores





Manycores

Arquitectura AMD Instinct

40

- Dos modelos:
 - OCP Accelerator Module (OAM - OCP Accelerator Module)
 - PCI express versión 5

Modelo	CUs	SPs por CU	Total SPs
MI100	120	64	7680
MI250x	220	64	14080
MI300x	304	64	19456



- Debido al gran número de cores estas arquitecturas se conocen como Manycores:

Manycore: Arquitectura de cómputo que posee decenas, cientos o miles de cores simples, diseñados para ejecutar múltiples tareas de manera altamente paralela.


- Propuestas de otros fabricantes:
 - Intel Xeon PHI (discontinuado)
 - Intel Xe
 - Pezy
 - Fujitsu
 - Sunway

Manycores Intel Xeon Phi

42

Primera Generación

- Basado en Cores X86 in-order (4 hilos)
- Conexión en anillo bi-direccional
- Conectividad vía bus PCIe
- Hasta 60 cores



Segunda Generación



- Basado en Atom
- Conexión en grilla
- Conectividad Processor Host
- Hasta 72 cores (278 Hilos)
- MCDRAM configurable
- Unidades Vectoriales 512bits (VPU)

- Grilla configurable:

All-to-All (UMA)

Quadrant/Hemisphere (UMA)



SNC-2/SNC-4 (NUMA)



Manycores Intel Xe

43

- Dos modelos:
 - Módulo OAM (OCP Accelerator Module)
 - Intel Data Center GPU Max 1550
 - PCI express versión 5:
 - Intel Data Center GPU Max 1100
- Entre 4 y 128 Xe cores
 - Motores vectoriales (FP32, FP64, INT)
 - Motores Matriciales (IA)
 - Múltiples operaciones por ciclo
- iGPU basadas en Xe-LP integradas en CPU, programables con OpenCL, Sycl, OneAPI.




Manycores


Otros manycores

44


Pezy



Fujitsu A64FX




Sunway TaihuLight





- **Field-Programmable Gate Array (FPGA):** Nacen en 1984.
- Circuitos reconfigurables: también para cómputo paralelo.
- Modelo clásico:
 - CLB (*Configurable Logic Blocks*)
 - BRAM (*Block RAM*)
 - DSP (*Digital Signal Processor*)





Cloud computing

48

- **1960-1970:** primeras ideas de Cloud Computing en Mainframes.
- **2000:** resurgimiento a partir de Virtualización.
- **Cloud Computing:** paradigma basado en la virtualización, que ofrece recursos y servicios a través de Internet.
- No es una arquitectura paralela pero ofrece servicios a sistemas paralelos complejos:
 - **Costos (monetarios y energía) de los sistemas de cómputo**
 - **Mantenimiento y actualización del hardware**
 - **Quantum cloud:** acceso a computadoras cuánticas (IBM, Amazon Braket)



Computación cuántica

Contexto histórico - El inicio de la Era Cuántica en Computación

50



Premio nobel en física Richard Feynman

Conferencia "Simulación de la física con computadoras".
Propuesta del uso de fenómenos cuánticos que supone mayor eficiencia en ciertos cálculos computacionales.



Algoritmo de Grover

Primera máquina con 2 qbits

1981

1982

1992

1994

1995

1996

1998

2025

Paul Benioff

Idea de computadora que aproveche principios de la mecánica cuántica.


Superposición, Entrelazamiento, Medición



Algoritmo Shor

Algoritmo Deutsch-Jozsa

Quantum bits equivalente cuántico al bit clásico.



Benjamin Schumacher

Acuña el término Qbit



Atom Computing 1180 qbits

IBM Condor 1121 qbits

IBM Osprey 433 qbits



Computación cuántica

Del bit al qbit - La unidad de información cuántica


51

- Un Bit Clásicos puede ser **0** o **1**, pero **solo un estado a la vez**.
- En computación cuántica, la **unidad de información** es el **Qbit**: puede ser **0**, **1** o una **superposición** de ambos estados al mismo tiempo, cada uno con cierta probabilidad.
- El número de qbits indica los estados que pueden estar en superposición:
 - Un **registro** con **8 bits clásicos** puede tomar **uno de 256 valores** posibles.
 - Un **registro** con **8 qbits cuánticos** puede tomar **todos los 256 valores a la vez**, permitiendo 256 operaciones paralelas.



Esfera de Bloch

Representación geométrica del espacio de estados puros de un sistema cuántico de dos niveles.



Computación cuántica

Representación de qbits - Tecnologías

52

- El desafío está en **cómo representar físicamente un qbit:**

- ¿Cómo implementar un qbit en hardware?
- ¿Qué sistema físico puede comportarse como un qbit?



- Ejemplos de tecnologías para implementar qbits:

- Qbits superconductores (IBM, Google)
- Iones atrapados (IonQ, Honeywell)
- Qbits fotónicos
- Puntos cuánticos / Qbits semiconductores
- Spin en diamante (NVC - Nitrogen-Vacancy centers)
- Átomos neutros
- Qbits topológicos
- Qbits de espín en semiconductores
- **Otras... (área de investigación abierta!!!)**



Computación cuántica

Representación de qbits- Era NISQ

53

- Varis tecnologías para implementar qbits, todas comparten:

- Tamaño limitado (decenas o cientos de qbits)
- Sistemas frágiles e imprecisos
- Mucho ruido (con errores de operación)
- Sin corrección de errores completa
- Sufren **decoherencia** (pierden rápido su estado cuántico - superposición y entrelazamiento)



- Actualmente, **era NISQ (Noisy Intermediate-Scale Quantum) - John Preskill (2018)**
 - Computadoras cuánticas funcionales, pero pequeñas e imprecisas para resolver problemas significativos.
 - El “**gran objetivo**” es llegar a la **ventaja cuántica** práctica (**quantum advantage**) e ir hacia la computación cuántica tolerante a fallos.
 - **Ventaja cuántica:** cuando una computadora cuántica resuelva un problema de manera mas eficiente que una computadora clásica. Incluso, que resuelva un problema muy difícil o imposible de resolver clásicamente.

Computación cuántica


Modelo de Programación

54

- Dos grandes enfoques para **programar computadoras cuánticas**:

Basada en circuitos cuánticos

- Modelo más extendido en las computadoras cuánticas actuales (IBM, Google, IonQ, Rigetti, Xanadu, etc.)
- Manipulación de qbits mediante puertas cuánticas (H, X, CNOT, etc.)
- Algoritmos construidos como circuitos (preparar, aplicar puertas y medir):




- Equivalente al modelo universal de computación

Basada en annealing cuántico

- Para problemas específicos de optimización combinatoria (D-Wave)
- No usa puertas cuánticas ni circuitos
- Se prepara un sistema que evoluciona hacia el estado de mínima energía del Hamiltoniano que codifica la función de costo del problema.


$$E = \langle \psi | H | \psi \rangle$$



- No es universal, solo para un tipo específico de problemas
- Ideal para optimización de rutas, satisfacción de restricciones (SAT), scheduling, clustering, problemas NP-hard...

- Objetivos:

- Llegar a computadoras cuánticas tolerantes a fallas (**fault-tolerant**)
- Con **millones de qbits** estables físicos



- Expectativas:

- Factorización de números enteros
- Criptografía cuántica
- Teleportación cuántica de la información
- Simulación de sistemas cuánticos (Físicos, Químicos y Biológicos)
- Inteligencia Artificial y Aprendizaje automático
 - (Quantum Machine Learning - Variational Neural Networks).
- Medicina e Industria Farmacológica
- Etc...

$$E = \frac{\langle \psi | H | \psi \rangle}{\langle \psi | \psi \rangle}$$



11


Paralelismo en otros dispositivos

Paralelismo en otros dispositivos

Internet de las cosas

57

- Dispositivos actuales compuestos por procesadores multicores.
- Concepto de **IoT** (*Internet of Things*):
 - Dispositivos interconectados a través de redes
 - Objetos “inteligentes”
 - Investigación y Desarrollo de robótica, domótica (casas inteligentes) y automatización industrial.
 - Sensores y Actuadores



Paralelismo en otros dispositivos

Single Board Computers (SBCs)

58

- IoT impulsó el desarrollo de **placas SBC** (*Single Board Computer*)
 - Bajo costo
 - Pequeñas
 - Múltiples características (Multicores, GPUs, E/S, Red, Almacenamiento)
- **Desventajas:** lentas y limitadas.
- **Ventajas:** costo, livianas, compactas, más confiables y eficientes energéticamente.
- Para aplicaciones integradas, aplicaciones de control de procesos (robótica y sensores).



Raspberry PI



Arduino




Nvidia Jetson

Paralelismo en otros dispositivos

Cloud – Edge – Fog

59

- Datos valiosos generados por dispositivos deben ser procesados para obtener información y mejorar la toma de decisiones.
- Necesidad de procesar datos en *Cloud* (por complejidad o gran volúmen).
- Problemas de latencia de *Cloud*. Soluciones:
 - **Edge Computing (mínima latencia):** procesamiento y almacenamiento de datos lo más cerca posible de los dispositivos que los generan.
 - **Fog Computing (latencia intermedia):** procesamiento en puntos intermedios, como *routers* o *gateways*.




Paralelismo en otros dispositivos

Computing Continuum

60

- **Computing Continuum:** aprovechar lo mejor de cada tipo de infraestructura para mejorar la eficiencia y reducir la latencia en la transmisión y el procesamiento de datos.
 - **Cloud:** análisis complejos y almacenamiento de datos a largo plazo.
 - **Edge:** procesamiento de datos que requieren decisiones rápidas (respuesta inmediata de un vehículo autónomo).
 - **Fog:** procesamiento intermedio.





12

Estado actual, tendencias y expectativas futuras

Estado actual, tendencias y expectativas futuras

62

- Evolución de arquitecturas paralelas impulsó el uso masivo de **Sistemas Paralelos**.
- Actualmente, todo tipo de procesamiento se realiza de manera paralela:
 - Big Data
 - IA
 - Simulaciones
 - ...



El Desafío actual: arquitecturas paralelas mas rápidas pero mas eficientes energéticamente debido a la demanda de energía de grandes centros de cómputo.





- Rankings elaborados dos veces por año (Junio y Noviembre) que evalúan sistemas de cómputo HPC:

Noviembre 2025	Top 500 Computadoras mas rápidas (Gflops) (https://www.top500.org/lists/green500/)	Green 500 Computadoras mas eficientes energéticamente (Gflops/Watt) (https://www.top500.org/lists/green500/)
1	HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, TOSS	BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux
2	HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE Cray OS	BullSequana XH3000, Grace Hopper Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, Red Hat Enterprise Linux
3	HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11	BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux
4	BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux	HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11

Estado actual, tendencias y expectativas futuras

64

- Los rankings muestran una combinación de arquitecturas paralelas:
 - **Clusters de máquinas multicore con GPUs.**
- Ventajas de combinar distintas tecnologías de cómputo paralelo, que forman **Sistemas Paralelos Híbridos** trabajando de forma colaborativa.
- La tendencia es ir incorporando nuevas tecnologías (por ejemplo QPUs).

El objetivo es encontrar la mejor herramienta para resolver un problema, ya sea utilizando una única arquitectura paralela o una combinación de varias, que garantice la solución más eficiente tanto en rendimiento como en eficiencia energética.



Próxima clase

Capítulo 5

Diseño de algoritmos paralelos.



